



מבוא

- בשבוע שעבר עסקנו בארבע ההנחות הראשונות:
 - 1. המודל לינארי בפרמטרים
 - 2. המדגם מקרי
 - 3. אין תלות לינארית מלאה בין המשתנים המסבירים
 - 4. הנחת התוחלת המותנה: $E(\varepsilon | X_1, \dots, X_k) = 0$
- השבוע נמשיך ונעסוק בהנחות:
 - 5. הומוסקדסטיות: $\text{var}(\varepsilon | X_1, \dots, X_k) = \sigma^2$
 - 6. הנחת הנורמליות: $\varepsilon \sim N$
- בנוסף, נלמד כיצד לנתח את סדרת השאריות וללמוד ממנה על קיום ההנחות.



הנחת ההומוסקדסטיות

- הנחה מספר 5, מניחה שונות שווה של השגיאה, ללא תלות בערכם של המשתנים המסבירים.



הנחת ההומוסקדסטיות

- הנחה מספר 5, מניחה שונות שווה של השגיאה, ללא תלות בערכם של המשתנים המסבירים.
- הנחה זו קריטית לצורך חישוב השונות של אומדי OLS ולתוקף הסטטיסטים F ו-t.
- ההנחה קריטית גם לצורך קיום משפט גאוס-מרקוב, כלומר, כשהנחה זו לא מתקיימת, אומדי OLS אינם אופטימאליים וקיימים אומדים חסרי הטייה בעלי שונות נמוכה יותר.
- לעומת זאת, לצורך חוסר ההטייה, הנחה 5 אינה נדרשת.

שונות אומדי OLS תחת הטרוסקדסטיות

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} - \frac{\bar{y} \sum_{i=1}^n (x_i - \bar{x})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

- נניח שבמקום שונות קבועה, לכל תצפית i מתקיים:
$$\text{var}(\varepsilon_i) = \sigma_i^2$$

- נחשב את שונות האומד ברגריסה פשוטה:


$$\begin{aligned} \text{var}(\hat{\beta}_1) &= \sum_{i=1}^n \left[\frac{(X_i - \bar{X})}{\sum_{i=1}^n (X_i - \bar{X})^2} \right]^2 \text{var}(Y_i) = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\left(\sum_{i=1}^n (X_i - \bar{X})^2 \right)^2} \sigma_i^2 = \\ &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2 \sigma_i^2}{\left(\sum_{i=1}^n (X_i - \bar{X})^2 \right)^2} \end{aligned}$$

שונות אומדי OLS תחת הטרוסקדסטיות

- שונות האומדים במקרה זה שונה מהשונות תחת הנחת ההומוסקדסטיות ולכן, האומד לשונות, כפי שהוצג קודם אינו חסר הטייה.
- אומד אחר לשונות, הנקרא אומד White, הינו אומד מוטה אך עקיב ולכן תקף רק במדגמים גדולים:

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2 e_i^2}{\left(\sum_{i=1}^n (X_i - \bar{X})^2 \right)^2}$$

דוגמא



דוגמא

```
##
## call:
## lm(formula = per_capita_exp ~ region + residents + young_residents +
##     per_capita_income, data = education)
##
##      Res.    SQ Median      SQ      Max
## 77.963 -25.495 -2.254 17.438 49.586
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -467.462827    311.310887  -1.5014  0.14056
## regionnortheast  15.727405     25.307782   0.6214  0.53759
## regionsouth     7.007124     25.561063   0.2808  0.76501
## regionwest     34.324157    24.122587   1.4229  0.16198
## residents      -0.034558     0.091844  -0.3763  0.70857
## young_residents  1.301458     0.688297   1.8908  0.06540
## per_capita_income 0.072036     0.029999   2.4013  0.02073
##
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 39.86 on 43 degrees of freedom
## Multiple R-squared:  0.3282, Adjusted R-squared:  0.3175
## F-statistic: 12.16 on 6 and 43 Df, p-value: 0.0000000
```

```
coeftest(lmfit, vcov = vcovHC(lmfit))
##
## t test of coefficients:
##
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    -467.462827    311.310887  -1.5014  0.14056
## regionnortheast  15.727405     25.307782   0.6214  0.53759
## regionsouth     7.007124     25.561063   0.2808  0.76501
## regionwest     34.324157    24.122587   1.4229  0.16198
## residents      -0.034558     0.091844  -0.3763  0.70857
## young_residents  1.301458     0.688297   1.8908  0.06540
## per_capita_income 0.072036     0.029999   2.4013  0.02073
##
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

הנחת הנורמליות

- הנחה מספר 6, מניחה התפלגות נורמלית של השגיאה.
- במידה וההנחה מופרת, התפלגותם של אומדי OLS לא ידועה ולכן אין תוקף לסטטיסטיים F - t .
- למזלנו, לאור העובדה שאומדי OLS הם סכום של מ"מ, ניתן להראות כי לפי משפט הגבול המרכזי, התפלגותם הגבולית היא נורמלית ללא תלות בהתפלגות השגיאות.
- מכאן, שהנחת הנורמליות קריטית רק במדגמים קטנים.
- ישנם מקרים בהם נוכל להתאים את המודל ע"י טרנספורמציה מתאימה ובכך "ליתקן" את נורמליות השגיאות.

ניתוח שאריות


- לאחר אמידת הרגרסיה, ניתן לחשב את סדרת

השאריות:
$$e_i = Y_i - (\hat{\beta}_0 + \sum_{j=1}^k \hat{\beta}_j X_{ji})$$

- ומסדרה זו ניתן ללמוד רבות על מידת קיום/אי-קיום ההנחות.


שאריות מול ערכי X או ערכים חזויים

- ע"י שרטוט גרף של השאריות מול ערכי X ניתן ללמוד על הפרות של הנחת התוחלת המותנה (4).
- במידה וההנחה מתקיימת נצפה לקבל גרף מהצורה הבאה:



שאריות מול ערכי X או ערכים חזויים

- אך במידה והנחה 4 אינה מתקיימת נצפה לקבל תבנית כלשהי, לדוגמה:




- מקרה כזה יכול להעיד למשל על צורך בגורם ריבועי

שאריות מול ערכי X או ערכים חזויים

- את הבדיקה ניתן לבצע מול כל משתנה מסביר או כל קומבינציה לינארית שלהם.
- לרוב, נהוג לבדוק את הקשר בין השאריות לערכים החזויים $\hat{y}_i$, שהם בעצמם קומבינציה לינארית של המשתנים המסבירים.


שאריות מול ערכי X או ערכים חזויים

- מהגרף ניתן ללמוד גם על קיום הנחה 5, הומוסקדסטיות.
- במידה וההנחה מתקיימת נצפה לקבל גרף כזה:



שאריות מול ערכי X או ערכים חזויים

- לעומת מצב של הטרוסקדסטיות, שם נראה פיזור לא אחיד, לדוגמה:




QQ-plot

- Quantile-Quantile plot הוא גרף להשוואת התפלגויות.
- נהוג לעשות בו שימוש לצורך בדיקת התאמת התפלגות אמפירית של סדרת נתונים להתפלגות תאורטית נתונה.
- ברגרסיה לינארית, ניתן לעשות בו שימוש לבדיקת הנחת הנורמליות.

QQ-plot

- על הציר האופקי של QQ-plot תופיע סדרת הנתונים המקורית.
- על הציר האנכי, תופיע סדרה המחושבת ע"י $F^{-1}(Q_i)$ כאשר F^{-1} היא הפונקציה ההפוכה של פונקציית ההתפלגות המצטברת אליה רוצים להשוות, ו- Q_i הוא האחוזון המתאים לתצפית ה- i .
- אם יש התאמה בין ההתפלגויות נצפה לראות את הנקודות קרובות לקו 45 מעלות.


QQ-plot



- לדוגמה:


QQ-plot

- לעומת זאת, מצב בו אין התאמה להתפלגות:



דוגמא

```
dataw=read.csv("C:/Users/elish/Google Drive/tirgul/bank_
dataw$lwage=log(dataw$wage)
modelw_1 <- lm(lwage ~ educ, data = dataw)
modelw_1
dataw$resid1=resid(modelw_1)
qqnorm(dataw$resid1, pch = 1, frame = FALSE)
qqline(dataw$resid1, col = "steelblue", lwd = 2)
```



רגרסיה לינארית מרובה – בדיקת השערות מורכבות

- השערה מורכבת היא השערה על יותר מפרמטר אחד, למשל:

$$H_0: \beta_1 = b_1, \beta_2 = b_2$$

H_1 : אחרת

- אפשרות אחת היא לבצע 2 מבחני T אך אז לא ממש ברור מהי רמת המובהקות של המבחן.

- הפתרון: מבחן F .

רגרסיה לינארית מרובה – בדיקת השערות מורכבות



- על מנת לבצע מבחן F נאמוד 2 רגרסיות, אחת רגרסיה "מוגבלת" המניחה שהשערת ה-0 נכונה, ואחת "לא מוגבלת" שלא מניחה דבר (הרגרסיה המקורית).
- כך למשל, הרגרסיה ה"מוגבלת" של ההשערות מהשקופית הקודמת היא:

$$Y_i = \beta_0 + b_1 X_{1i} + b_2 X_{2i} + \beta_3 X_{3i} \cdots + \beta_k X_{ki} + \varepsilon_i$$

- ומכיוון ש- b_1, b_2 אינם פרמטרים אלא מספרים קבועים, נאמוד את הרגרסיה:

$$Y_i - b_1 X_{1i} - b_2 X_{2i} = \beta_0 + \beta_3 X_{3i} \cdots + \beta_k X_{ki} + \varepsilon_i$$

רגרסיה לינארית מרובה – בדיקת השערות מורכבות



- עבור כל אחת משתי הרגרסיות ניתן לחשב את SSE ונסמן ב- SSE_{UR} עבור הרגרסיה הלא מוגבלת וב- SSE_R עבור הרגרסיה המוגבלת.
- שימו לב כי חייב להתקיים: $SSE_R \geq SSE_{UR}$

$$F = \frac{\frac{SSE_R - SSE_{UR}}{q}}{\frac{SSE_{UR}}{n-k-1}} \sim F_{q, n-k-1} \quad \text{סטטיסטי } F \text{ יהיה:}$$

- כאשר q הוא מספר האילוצים תחת השערת ה-0

רגרסיה לינארית מרובה – בדיקת השערות מורכבות



- ככל שהשערת ה-0 יותר "נכונה" כך נצפה לערך F נמוך יותר.

- ולכן, נדחה את השערת ה-0 אם $F > F_{q, n-k-1, 1-\alpha}$

$$F = \frac{\frac{SSE_R - SSE_{UR}}{q}}{\frac{SSE_{UR}}{n-k-1}} \sim F_{q, n-k-1}$$

דוגמא

- עבור הרגרסיה הבאה:
$$lwage = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 IQ + \beta_4 age + \epsilon$$
- נבדוק את ההשערה כי age ו- $exper$ לא משפיעים על השכר
- כלומר:

$$H_0: \beta_2 = \beta_4 = 0$$

$$H_1: otherwise$$

```
UR <- lm(lwage ~ educ+exper+IQ+age, data = dataw)
R <- lm(lwage ~ educ+IQ, data = dataw)
```

דוגמא 1

$$F = \frac{\frac{SSE_R - SSE_{UR}}{q}}{\frac{SSE_{UR}}{n-k-1}} \sim F_{q, n-k-1}$$

```
UR <- lm(lwage ~ educ+exper+IQ+age, data = dataw)
R <- lm(lwage ~ educ+IQ, data = dataw)
```

```
> summary(UR)
Call:
lm(formula = "lwage ~ educ + exper + IQ + age, data = dataw")

Residuals:
    Min       1Q   Median       3Q      Max
-1.90656 -0.21228  0.02454  0.25464  1.30919

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.858277    0.384242   12.622 < 2e-16 ***
educ         0.039337    0.007020    5.558 3.13e-11 ***
exper        0.013178    0.003871    3.402 0.00088 ***
IQ           0.005829    0.000774    7.521 1.15e-09 ***
age          0.014485    0.004871    2.973 0.00308 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3845 on 932 degrees of freedom
Multiple R-squared:  0.125, Adjusted R-squared:  0.124
F-statistic: 47.67 on 4 and 932 DF, p-value: < 2.2e-16

> summary(R)
Call:
lm(formula = "lwage ~ educ + IQ, data = dataw")

Residuals:
    Min       1Q   Median       3Q      Max
-2.01601 -0.24367  0.03359  0.27960  1.23783

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  5.6582876    0.0962408   58.793 < 2e-16 ***
educ         0.0393199    0.0068382    5.721 1.45e-09 ***
IQ           0.0058881    0.0009979    5.875 5.87e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.3933 on 932 degrees of freedom
Multiple R-squared:  0.125, Adjusted R-squared:  0.124
F-statistic: 69.42 on 2 and 932 DF, p-value: < 2.2e-16
```

$$\frac{0.3933 \cdot 932 - 0.3845 \cdot 930/2}{0.3845 \cdot 930 / (935 - 4 - 1)} = 11.66$$

```
> df(11.66, 2, 930)
[1] 9.723392e-06
```

דוגמא 2

```
> summary(model)
Call:
lm(formula = "sales ~ youtube + facebook + newspaper, data = marketing")

Residuals:
    Min       1Q   Median       3Q      Max
-10.5932 -1.0690  0.2902  1.4272  3.3951


Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.526657    0.374290    9.422 < 2e-16 ***
youtube      0.045765    0.001395   32.809 < 2e-16 ***
facebook     0.188530    0.008611   21.893 < 2e-16 ***
newspaper    +0.001037    0.005871   +0.177    0.86

(Intercept) ***
youtube      ***
facebook     ***
newspaper    ---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.023 on 196 degrees of freedom
Multiple R-squared:  0.8972, Adjusted R-squared:  0.8956
F-statistic: 570.3 on 3 and 196 DF, p-value: < 2.2e-16
```

$$H_0: \beta_1 = \beta_2 = \beta_3 = 0$$

$$H_1: otherwise$$





נפילת הבנקים
הגדולה

מה זה בנק



הריצה אל הבנקים






מדיניות מוניטרית ומשברים כלכליים



אז מה אפשר לעשות ?



One Mississippi, Two Mississippi


ניסוח פורמלי

- נסמן ב- Y_{dt} את מספר הבנקים הפתוחים במחוז d בזמן t
- d יכול לקבל את הערכים 6 או 8
- t יכול לקבל את הערכים 1930 או 1931 - לפני או אחרי המשבר
- אומדן DD (δ_{DD}) של "הכסף הקל" במחוז 6 הוא:
$$\delta_{DD} = (Y_{6,1931} - Y_{6,1930}) - (Y_{8,1931} - Y_{8,1930})$$
$$= (121 - 135) - (132 - 165)$$
$$= -14 - (-33) = 19$$

ניסוח פורמלי


- בנקים לראשונה את מספר הבנקים הפתוחים ברובע השישי והשמיני אחרי המשבר, DD משווה את השינוי במספר הבנקים הפועלים בשני המחוזות.
- השוואת שישים במקום חוות לקוחות בחשבון את העובדה שבחלק מהשנים שקדמה למשבר (טיוטל) היו ברובע השמיני יותר בנקים פתוחים מאשר השישי. כדי לראות את שיעור לקבל את אותה התפיסה של DD בדרך א.
$$\delta_{DD} = (Y_{6,1931} - Y_{6,1930}) - (Y_{8,1931} - Y_{8,1930})$$
$$= (121 - 132) - (135 - 165)$$
$$= -11 - (-30) = 19$$
- גרסה זו של חישוב DD מפתחת את ההפרש לפני הטיפול בין המחוזות השישי למחוזות השמיני מההפרש לאחר המשבר, ובכך לוקחת בחשבון את העובדה ששני המחוזות לא היו יזמים בתחילה.
- הגרסה DD מתקיימת על כך שרולאשנות לבנקים בעייתיים שמוזעזזו על ידי המשבר פתחו בנקים. באופן מקסימלי נראה כי הפד של אומדן החל 19 בנקים - יותר מ- 10% מאלו שפעלו ברובע השישי של מרסידיס בשנת 1930

Bank failures in the Sixth and Eighth Federal Reserve Districts




Notes: This figure shows the number of banks in operation in Mississippi in the Sixth and Eighth Federal Reserve Districts in 1929 and 1931. The dashed line depicts the counterfactual evolution of the number of banks in the Sixth District if the same number of banks had that district in this period as did in the Eighth.

Trends in bank failures in the Sixth and Eighth Federal Reserve Districts



c: This figure shows the number of banks in operation in Mississippi in the Federal Reserve Districts between 1929 and 1934.

Trends in bank failures in the Sixth and Eighth Federal Reserve Districts, and the Sixth District's DD counterfactual




This figure adds DD counterfactual outcomes to the banking data plotted in Figure 5. The dashed line depicts the counterfactual evolution of the number of banks in the Sixth District if the number of banks had failed in that district after 1930 as did in the Eighth.


הרעיון המרכזי של DID

- אם אנו יכולים לצפות בתוצאות ברמה הקבוצתית מספר פעמים (לפחות פעם אחת לפני ואחר הטיפול)
- ואם אנחנו יכולים להניח כי בהיעדר טיפול, המשתנה שמעניין אותנו בקבוצת הטיפול וקבוצת הביקורת "זז" באופן מקביל – כלומר אותה מגמה
- אז בהשוואת המגמה הנצפית של קבוצת הטיפול למגמה נגד של קבוצת הביקורת, אנו יכולים לקבל השפעה סיבתית של הטיפול


אינטואיציה
ויזואלית



אינטואיציה
ויזואלית



אינטואיציה ויזואלית



An Example of Difference-in-Differences Card & Krueger (1994)

- David Card and Alan B. Krueger (1994) "Minimum Wages and Employment: A Case Study of the Fast-Food Industry in New Jersey and Pennsylvania" AER
- They want to estimate the causal effect of raising minimum wage on employment of low-skilled workers



Card & Krueger (1994)

- What is the effect of increasing the minimum wage on employment?
- Minimum wage is binding only in certain jobs:
 - Low-skilled jobs
 - Often teenage workers
- How much does an increase in the minimum wage reduce demand for low-skilled workers?
- In a competitive labor market, increases in the minimum wage would move up a downward-sloping labour demand curve.
- Employment would fall.

Card & Krueger (1994)

- Card & Krueger (1994) analyze the effect of a minimum wage increase in New Jersey (NJ) using a DID methodology
- In February 1992 NJ increased the state minimum wage from \$4.25 to \$5.05
- Pennsylvania (PA)'s minimum wage stayed at \$4.25
- They surveyed about 400 fast food stores both in NJ and in PA both before and after the minimum wage increase in NJ.



Card & Krueger (1994)

- Two groups:
 - treatment group: NJ
 - control group: PA
- Two periods:
 - Pre-treatment period: February 1992
 - Post-treatment period: November 1992
- Let Y_{st} denote the average employment in state s at time t (in the surveyed fast food restaurants)

Card & Krueger (1994)

- To estimate the effect of minimum wage on employment in NJ, we would like to know the following counterfactual:
 - In absence of raising minimum wage to \$5.05, what would avg emp in NJ be?
- DID method suggests we construct the counterfactual employment in NJ by using:
 - Average employment level in NJ before reform +
 - The trend in average employment level in PA (control group)


$$Y_{NJ, Feb} + (Y_{PA, Nov} - Y_{PA, Feb})$$

Card & Krueger (1994)

- We can identify the effect of minimum wage on employment in NJ by taking difference in realized employment and counterfactual employment in NJ:

$$\begin{aligned}\delta_{DID} &= Y_{NJ,Nov} - [Y_{NJ,Feb} + (Y_{PA,Nov} - Y_{PA,Feb})] \\ &= (Y_{NJ,Nov} - Y_{NJ,Feb}) - (Y_{PA,Nov} - Y_{PA,Feb})\end{aligned}$$

- If PA is a good control group,
- The trend in PA emp should absorb any other changes over time in emp that are unrelated to the increase in min wage



Card & Krueger (1994)

Card & Krueger (1994)

$$\begin{aligned}\delta_{DD} &= (Y_{NJ,Nov} - Y_{NJ,Feb}) - (Y_{PA,Nov} - Y_{PA,Feb}) \\ &= (21.03 - 20.44) - (21.17 - 23.33) \\ &= 0.59 - (-2.16) = 2.76\end{aligned}$$

- Instead of just comparing NJ emp in Feb (before reform) to NJ emp in Nov (after reform),
- DID adjusts for change (trend) in labor demand (emp) in the absence of a min wage hike
- A simple after vs. before comparison is better than nothing, but other things could have changed over time

Card & Krueger (1994)

$$\begin{aligned}\delta_{DD} &= (Y_{NJ,Nov} - Y_{PA,Nov}) - (Y_{NJ,Feb} - Y_{PA,Feb}) \\ &= (21.03 - 21.17) - (20.44 - 23.33) \\ &= (-0.14) - (-2.89) = 2.76\end{aligned}$$

- Also, instead of just comparing employment in NJ vs. PA post reform,
- DID adjusts for the fact that in the pre-reform period, NJ had less emp PA
- i.e. there are likely to be baseline differences between NJ and PA that confound that comparison

Stores by state

Variable	PA	NJ	Difference, NJ-PA
	(i)	(ii)	(iii)
1. Mean employment at February 1992	23.33 (1.35)	20.44 (0.51)	-2.89 (1.44)
2. Mean employment at November 1992	21.17 (0.94)	21.03 (0.52)	-0.14 (1.07)
3. Change in mean employment between Feb and Nov	-2.16 (1.25)	0.59 (0.54)	2.76 (1.44)

Card & Krueger (1994)

- Surprisingly, employment rose in NJ relative to PA after the minimum wage change.

אמידה של DID

- אם יחלים לאמוד את אנומליה ה-DID במסגרת רגרסיה יתרופת:
- קל לחשב סטיות תקן
- אם יחלים לשלש על משתנים אחרים אשר עשויים להפחית את שגיאת הטעות (מביל לטויות תקן קטנות יותר)
- קל לכלול מספר תקופות
- אם יחלים ללמוד טיפולים בשגיאת טיפול שונה (למשל, עלויות משתנות בשכר המינימום עבור מדינות שונות): DID רצף

שנה	קבוצה	פר
2019	1a	98
2019	1a	89
2019	1a	56
2020	1a	78
2020	1a	34
2020	1a	56
2019	2a	24
2019	2a	54
2019	2a	100
2020	2a	95
2020	2a	83
2020	2a	73
2020	2a	80

אמידה של DID

- מקרה הבסיס: שתי קבוצות ושתי תקופות
- כדי ליישם את שיטת DID במסגרת רגרסיה, אם אומדים:

$$Y_{ist} = \mu + \gamma D_i + \delta Post_t + \delta_{DD}(D_i \cdot Post_t) + \epsilon_{ist}$$
- D הוא משתנה דמה המעיד על טיפול
- $Post$ הוא משתנה דמה המציי תקופה לאחר הטיפול
- γ לוכד הבדלים קבועים לאורך זמן בין קבוצות (fixed effect)
- δ לוכד הבדלים לאורך זמן המשותפים לכל הקבוצות
- δ_{DD} הוא המקדם המעניין (ההשפעה הסיבתית של הטיפול)

אמידה של DID

$$Y_{ist} = \mu + \gamma D_i + \delta Post_t + \delta_{DD}(D_i \cdot Post_t) + \epsilon_{ist}$$

• אם $E[\epsilon_{ist} | D, Post] = 0$
 אז אפשר להראות ש-

- Pre-treatment mean of outcome for control group:
 $E[Y_{ist} | D = 0, Post = 0] = \mu$
- Post-treatment mean of outcome for control group:
 $E[Y_{ist} | D = 0, Post = 1] = \mu + \delta$
- Pre-treatment mean of outcome for treatment group:
 $E[Y_{ist} | D = 1, Post = 0] = \mu + \gamma$
- Post-treatment mean of outcome for treatment group:
 $E[Y_{ist} | D = 1, Post = 1] = \mu + \gamma + \delta + \delta_{DD}$

	Pre	Post	Pre/Post difference
Control Group	μ	$\mu + \delta$	δ
Treatment Group	$\mu + \gamma$	$\mu + \gamma + \delta + \alpha_{DID}$	$\delta + \alpha_{DID}$
DID			α_{DID}

אמידה של DID
