



מבוא

- בשבועות האחרונים עסקנו ברגרסיה לינארית.
- הרגרסיה הלינארית היוותה מודל סטטיסטי המתאר קשר בין משתנים מסבירים למשתנה מוסבר Y .
- המודל כלל כמה הנחות מגבילות על צורת הקשר בין X ו- Y וכן על התפלגות המשתנה Y .
- השבוע, ננסה להכליל את המודל הנ"ל כך שהמודל החדש יוכל להתמודד עם סוגי קשרים שונים וכן התפלגויות שונות של המשתנה המוסבר Y .



התפלגות משותפת

- ניתן להגדיר יותר ממשתנה מקרי אחד בכל מרחב מדגם.
- לדוגמה, מטילים סביבון המסומן במספרים 1-4 פעמיים.
- יהי X תוצאת ההטלה הראשונה ויהי Y סכום ההטלות.
- נבנה את פונקציית ההתפלגות המשותפת.



דוגמה

- נבנה את פונקציית ההתפלגות המשותפת.

Y	2	3	4	5	6	7	8	
X								
1								$P(X=x)$
2								
3								
4								
	$P(Y=y)$							

דוגמה

- נבנה את פונקציית ההתפלגות המשותפת.

Y	2	3	4	5	6	7	8	
X								
1	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	0	0	0	$\frac{1}{4}$
2	0	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	0	0	$\frac{1}{4}$
3	0	0	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	0	$\frac{1}{4}$
4	0	0	0	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{4}$
	$\frac{1}{16}$	$\frac{2}{16}$	$\frac{3}{16}$	$\frac{4}{16}$	$\frac{3}{16}$	$\frac{2}{16}$	$\frac{1}{16}$	1

התפלגות מותנה

- ניתן לחשב את ההתפלגות המותנה של X בהינתן ערך מסוים של Y :

$$P(X=x|Y=y) = \frac{P(X=x \cap Y=y)}{P(Y=y)}$$

התפלגות מותנה - דוגמה

- ההתפלגות המותנה של X בהינתן $Y = 3$:

x	1	2						
$P(X = x Y = 3)$	$\frac{1}{2}$	$\frac{1}{2}$						
Y	2	3	4	5	6	7	8	
X								
1	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	0	0	0	$\frac{1}{4}$
2	0	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	0	0	$\frac{1}{4}$
3	0	0	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	0	$\frac{1}{4}$
4	0	0	0	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{16}$	$\frac{1}{4}$
	$\frac{1}{16}$	$\frac{2}{16}$	$\frac{3}{16}$	$\frac{4}{16}$	$\frac{3}{16}$	$\frac{2}{16}$	$\frac{1}{16}$	1

תוחלת מותנה

- ניתן לחשב את התוחלת המותנה של X בהינתן ערך מסוים של Y באמצעות ההתפלגות המותנה:

$$E(X | Y = y) = \sum_x xP(X = x | Y = y)$$

תוחלת מותנה - דוגמה

- תוחלת ערך ההטלה הראשונה בהינתן שסכום ההטלות שווה 3:

$$E(X | Y = 3) = \sum_x xP(X = x | Y = 3) = 1 \cdot \frac{1}{2} + 2 \cdot \frac{1}{2} = 1.5$$


x	1	2
$P(X = x Y = 3)$	$\frac{1}{2}$	$\frac{1}{2}$

מבוא- משמעות הרגרסיה

- הנחה 4 - $E(\epsilon|X_1, \dots, X_k) = 0$
- משמעות: התוחלת המותנית של Y בהינתן $X_1, \dots, X_k$ היא פונקציה ליניארית של $X_1, \dots, X_k$
 $Y = \beta_0 + \beta_1 X + \epsilon$
- ניקח תוחלת מותנה ב- X
 $E(Y|X) = \beta_0 + \beta_1 X$

מבוא – משמעות הרגרסיה

- $E(Y|X) = \beta_0 + \beta_1 X$
- כלומר, בהינתן $Y = \beta_0 + \beta_1 X + \epsilon$ משמעות ההנחה – $E(\epsilon|X) = 0$
- קו הרגרסיה באוכלוסייה הוא קו התוחלת המותנה!
- אנחנו רוצים לבדוק איך $E(Y|X)$ משתנה עם X



מוטיבציה

- לצורך פיתוח שיטה לזיהוי של גידולים בשד כשפירים או סרטניים נדגמו 569 גידולים שסווגו כשפירים או סרטניים, ונאספו נתונים על התאים שבכל גידול. למשל:
- רדיוס התא - radius
- מרקם התא - texture
- היקף התא - perimeter
- שטח הפנים של התא - area

מוטיבציה

- איך נראים הנתונים במקרה זה?

סוג הגידול	רדיוס התא	מרחק התא	היקף התא	שטח הפנים של התא
שפיר				
שפיר				
סרטני				
סרטני				
סרטני				
שפיר				

- אנחנו כבר יודעים מה לעשות...

מוטיבציה

- איך נראים הנתונים במקרה זה?

סוג הגידול	רדיוס התא	מרחק התא	היקף התא	שטח הפנים של התא
0				
0				
1				
1				
1				
0				

- ובכל זאת, יש פה בעיה ...

מוטיבציה

- במודל זה, המשתנה המוסבר, Y הוא משתנה דמי, המקבל את הערכים 0 ו-1.
- ניתן לשים לב מיד, כי הנחת הנורמליות מופרת שכן התפלגות מ"מ המקבל את הערכים 0 ו-1 היא התפלגות ברנולי.

מוטיבציה

- נזכיר, כי עבור $Y \sim \text{Ber}(p)$ מתקיים:

$$E(Y) = 1 \cdot p + 0 \cdot (1-p) = p$$

$$E(Y^2) = 1^2 \cdot p + 0^2 \cdot (1-p) = p$$

$$\text{var}(Y) = E(Y^2) - E(Y)^2 = p - p^2 = p(1-p)$$

- ולכן גם הנחת ההומוסקדסטיות מופרת שכן שונות המשתנה המוסבר אינה קבועה.

מודל ההסתברות הלינארית

- בשבוע שעבר, ראינו כי הנחת הנורמליות אינה קריטית שכן במדגמים גדולים, ההתפלגות הגבולית של האומדים עדיין נורמלית, וכן למדנו כיצד להתמודד עם הטרוסקדסטיות.
- לכן, בשלב ראשון ננסה לבדוק את משמעות מודל הרגרסיה הלינארית במקרה זה ללא התאמות נוספות.
- נזכיר כי במודל הרגרסיה הלינארית:

$$\sum_{j=0}^k \beta_j X_j = E(Y | X_1, \dots, X_k)$$

$(X_0 = 1)$

מודל ההסתברות הלינארית


- ובמקרה שלנו, מתפלג ברנולי ולכן מתקיים:

$$\sum_{j=0}^k \beta_j X_j = E(Y | X_1, \dots, X_k) = P(Y=1 | X_1, \dots, X_k)$$

- כלומר משמעות קו הרגרסיה היא **ההסתברות** שהמשתנה הבינארי יקבל את הערך 1 בהינתן ערכי המשתנים המסבירים.
- משמעות המקדם β_j היא ההשפעה השולית של המשתנה X_j על ההסתברות של Y לקבל את הערך 1.
- לכן, מודל זה נקרא מודל ההסתברות הלינארית.

מודל ההסתברות הלינארית

- במודל זה בעיה יסודית נוספת מלבד הבעיות שתוארו קודם.
- לאור לינאריות המודל, אין הבטחה שהגודל $\sum_{j=0}^k \beta_j X_j$ "יתנהג יפה" וייתן ערכים המשקפים הסתברות, כלומר ערכים בין 0 ל-1:



מודל ההסתברות הלינארית

- ניתן לבדוק את חומרת הבעיה ע"י בדיקת אחוז הערכים החזויים במדגם אשר גדולים מ-1 או קטנים מ-0.
- במידה ולא קיימים ערכים רבים החורגים מהטווח, משמעות הדבר היא שניתן להשתמש במודל למרות מגבלותיו, תוך שימת לב כמובן להפרת ההנחות.
- אך במידה וקיימים ערכים רבים החורגים מהטווח, המשמעות היא שלא ניתן להשתמש במודל במקרה זה ועלינו לחפש אלטרנטיבה.

גרסיה לוגיסטית

- לפי מודל ההסתברות הלינארית:
$$E(Y) = p = \sum_{j=0}^k \beta_j X_j$$
- ועקב כך הייתה סכנה שהערכים יחרגו מהטווח (0,1).
- בגרסיה הלוגיסטית, אנו מניחים כי הקשר בין p למשתנים המסבירים אינו לינארי אלא מקיים:
$$E(Y) = p = \text{logit}^{-1}\left(\sum_{j=0}^k \beta_j X_j\right) = \frac{e^{\sum_{j=0}^k \beta_j X_j}}{e^{\sum_{j=0}^k \beta_j X_j} + 1}$$
- וכך מובטח לנו שהערכים החזויים אכן יהיו בטווח (0,1).

רגרסיה לוגיסטית



• הפונקציה: $\text{logit}^{-1}(x) = \frac{e^x}{e^x + 1} = \frac{1}{1 + e^{-x}}$

היא פונקציית ההתפלגות המצטברת של מ"מ בעל התפלגות לוגיסטית ומכאן השם רגרסיה לוגיסטית.

• דרך נוספת להצגת המודל היא:

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right) = \sum_{j=0}^k \beta_j X_j$$

רגרסיה לוגיסטית



• משמעות המקדם β_j במקרה זה היא ההשפעה השולית של X_j על $\log(p/(1-p))$.

• הגודל $p/(1-p)$ נקרא יחס הסיכויים (Odds), כלומר פי כמה גדול הסיכוי ל"הצלחה" מאשר הסיכוי ל"כשלון".

• לכן, משמעות β_j ברגרסיה הלוגיסטית היא השינוי הצפוי באחוזים של יחס הסיכויים בעקבות גידול של יחידה אחת במשתנה X_j , כשכל הגורמים האחרים קבועים.

אמידת המודל



• לאור העובדה שיצאנו מהגדרת מודל הרגרסיה הלינארית, לא נוכל להשתמש באומדי OLS כבעבר.

• הדרך המקובלת לאמידת המודל היא הנראות המרבית.

• נשים לב כי עבור מ"מ ברנולי מתקיים:

$$P(Y = y) = p^y (1-p)^{1-y}$$

אמידת המודל

- ומכאן, פונקציית הנראות עבור המודל הנ"ל היא:

$$L(\beta) = \prod_{i=1}^n \left[\frac{e^{\sum_{j=0}^k \beta_j X_{ij}}}{e^{\sum_{j=0}^k \beta_j X_{ij}} + 1} \right]^{Y_i} \left[\frac{1}{e^{\sum_{j=0}^k \beta_j X_{ij}} + 1} \right]^{1-Y_i}$$

- לאור מורכבות פונ' הנראות במקרה הכללי, לא קיים פתרון סגור עבור אומדי הנראות המרבית ולכן, לצורך האמידה מתבצעת אופטימיזציה נומרית של פונקציית הנראות.

אמידת המודל

- לאור העובדה שאמידת המודל מתבצעת בשיטת הנראות המרבית, תחת תנאים מסוימים, האומדים המתקבלים מקיימים תכונות אסימפטוטיות (שלא נלמד בקורס זה).
- התפלגות האומדים שואפת להתפלגות נורמלית וניתן לחשב את האומד לשונות האומדים.
- לכן, נוכל לבצע הסקה סטטיסטית לגבי האומדים כפי שראינו ברגרסיה לינארית.

אמידת המודל ב-R

pregnant	glucose	pressure	triceps	insulin	mass	pedigree	age	diabetes
1	89	66	23	94	28.1	0.167	21	neg
0	137	40	35	168	43.1	2.288	33	pos
3	78	50	32	88	31.0	0.248	26	pos
2	197	70	45	543	30.5	0.158	53	pos
1	189	60	23	846	30.1	0.398	59	pos
5	166	72	19	175	25.8	0.587	51	pos
0	118	84	47	230	45.8	0.551	31	pos
1	103	30	38	83	43.3	0.183	33	neg

אמידת המודל ב-R

```
# Load the data and remove NAs
install.packages("mlbench")

data=data("PimaIndiansDiabetes2", package = "mlbench")
data <- na.omit(PimaIndiansDiabetes2)




# Fit the model
model <- glm( diabetes ~glucose, data = data, family = binomial)
summary(model)$coef
```

```
> summary(model)$coef
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -6.09552139  0.629787038 -9.678703 3.713993e-22
glucose      0.04242099  0.004760623  8.910805 5.066328e-19
```

דוגמא

```
probability curve
glucose=data$glucose
prob_pos=exp(-6.09 + 0.042*x)/(1 + exp(-6.09 + 0.042*x))

plot(glucose,prob_pos)
title("Logistic Regression Model",xlab="Plasma Glucose Concentration",ylab = "Probability of")
```



יותר ממשתנה מסביר אחד

```
model <- glm( diabetes ~ pregnant + glucose + pressure + mass + pedigree,
             data = data, family = binomial)
```

```
> summary(model1)$coef
              Estimate Std. Error z value Pr(>|z|)
(Intercept) -9.605739557 1.161994184 -8.2665987 1.378350e-16
pregnant     0.153411061 0.042221003  3.6335248 2.795756e-04
glucose      0.038184785 0.004918039  7.7642304 8.214249e-15
pressure     0.003577172 0.011684323  0.3061514 7.594893e-01
mass         0.076604944 0.021641331  3.5397520 4.005032e-04
pedigree     1.240835507 0.422712448  2.9354127 3.331043e-03
```

מודל Probit

- במודל הרגרסיה הלוגיסטית, הפעלנו על $\sum_{j=0}^k \beta_j X_j$ את פונקציית ההתפלגות המצטברת של ההתפלגות הלוגיסטית.

- אך כל פונקציית התפלגות מצטברת אחרת הייתה עושה את העבודה (ערכים בטווח $(0,1)$).

- במודל Probit, נעשה שימוש בפונקציית ההתפלגות המצטברת של ההתפלגות הנורמלית סטנדרטית, Φ :


$$E(Y) = p = \Phi\left(\sum_{j=0}^k \beta_j X_j\right)$$

מודל Probit

```
#probit
glm(formula = diabetes ~ glucose, family = binomial(link = "probit"), data = data)
```


```
call: glm(formula = diabetes ~ glucose, family = binomial(link = "probit"),
data = data)
```

```
Coefficients:
(Intercept)      glucose
-3.59591         0.02501
```




מודל Probit

- פירוש המודל הוא, ש- $\sum_{j=0}^k \beta_j X_j$ הוא ציון התקן המתאים להסתברות של Y להיות שווה 1:



מודל Probit

- יש להיזהר בפירוש המקדמים.
- במודל זה, עלייה של יחידה בערכו של המשתנה X_j , מעלה את ציון התקן, $\sum_{j=0}^k \beta_j X_j$ ב- β_j יחידות.
- עלייה זו לא מבטאת עלייה קבועה בהסתברות של Y להיות שווה 1!
- העלייה תלויה בערכו של ציון התקן המקורי לפני השינוי:



מודל Probit

- נהוג לחשב את השפעת כל משתנה בנקודת הממוצעים של המשתנים המסבירים.

RDD




השרירותיות יכולה להוביל לניסויים מעניינים



השרירותיות יכולה להוביל לניסויים מעניינים


RDD -
Regression
Discontinuity
Design



גיל שתייה חוקי


גיל מינימום לרישית אלכוהול לפי מדינה:

לא חוקי
גיל 25
גיל 21
גיל 20
גיל 19
גיל 18
גיל 17
גיל 16
לא ידוע



- ההיסטוריה של החוק יצרה מצבים של שני ניסויים טבעיים שיכולים לשמש אותנו כדי להערכה פקחית של מדיניות האלכוהול
- הראשון – שמיים קטנים בגיל (מים וחודשים) יוצרים פער גדול בגישה החוקית לאלכוהול
- כדי לראות מה ה"פח" של יום אחד נסתכל בגרף הבא: מקר מוות בקרב אמריקאים בגיל 20-22 בין השנים 1997-2003

A sharp RD estimate of MLDA mortality effects



Notes: This figure plots death rates from all causes against age in months. The lines in the figure show fitted values from a regression of death rates on an over-21 dummy and age in months (the vertical dashed line indicates the minimum legal drinking age (MLDA) cutoff).

Sharp RD

ניסוח השאלה

- השאלה הסיבתית שבה עוסק הגרף הקודם היא ההשפעה של גישה חוקית לאלכוהול על שיעור התמותה.
- המשתנה המסביר/משתנה הטיפול יהיה: D_a , כאשר $D_a = 1$ כאשר הוא מצוין כי לפרט יש גישה חוקית לאלכוהול וכאשר $D_a = 0$ - אין גישה חוקית
- D_a הוא פונקציה של הגיל שאותו נסמן ב- a ולק מתמטית ניתן לרשום:
$$D_a = \begin{cases} 1 & \text{if } a \geq 21 \\ 0 & \text{if } a < 21 \end{cases}$$
- D_a הוא פונקציה דטרמיניסטית של a כי אם אנחנו יודעים את a אנחנו יודעים גם את D_a
- משתנה הטיפול הוא פונקציה לא רציפה של a כי לא משנה כמה נהיה קרובים לסף, D_a "ישאר" ללא שינוי עד שנגיע אליו

כמה הגדרות

- a - הגיל, נקרא באופן כללי running variable
- sharp RD designs - הטיפול "נכבה" או "פועל" באופן "נקי", כלומר, מושלם, כאשר משתנה הריצה עובר את הסף כמו בסיפור שלנו
- fuzzy RD - בהן ההסתבחות או שצמת הטיפול משתנה בסף (נראה דוגמא בהמשך)


הרגרסיה המתאימה

- $$\overline{M}_a = \beta_0 + \beta_1 D_{age} + \beta_2 age + \epsilon$$
- כאשר:
- $\overline{M}_a$ - שיעור התמותה בחודש a
 - משתנה הגיל age נכנס בתור משתנה מפקח
 - אם נרץ את ההרגרסיה ונקבל את ערכי האומדנים נקבל את הקווים שראינו בגרף
 - השיפוע השלילי שנתפס על ידי β_2 מבטא את הירידה החלקה בשיעור התמותה ככל שהגיל עולה
 - הפרמטר β_1 תופס את הקפיצה בשיעור התמותה בגיל 21 בסיפור שלנו האומדן הוא של 7.7

הרגרסיה המתאימה

$$\beta_1 > 0, \beta_2 < 0$$

$$\begin{aligned}\overline{M}_a &= \beta_0 + \beta_1 D_{age} + \beta_2 age + \epsilon \\ \overline{M}_a &= \beta_0 + \beta_2 age + \epsilon : 21 \text{ גיל} \cdot \\ \overline{M}_a &= \beta_0 + \beta_1 + \beta_2 age + \epsilon : 21 \text{ אחרי גיל} \cdot\end{aligned}$$




האם זה מספיק?

- האם זו אומדן אמין של ההשפעה הסיבתית של גיל השתייה החוקי? האם אנחנו לא צריכים לשלוט בדברים אחרים?
$$\overline{M}_a = \beta_0 + \beta_1 D_{age} + \beta_2 age + \epsilon$$
- הנוסחה של השמנת משתנה אומרת לנו שההבדל בין האומדן של β_1 בהרגרסיה "הקצרה" שלנו לבין כל רגרסיה "ארוכה" יותר אחרת – תלוי בקורלציה בין המשתנים שנוספו לרגרסיה הארוכה לבין D_a ... אבל...
- $D_{age} - D_{age} = \begin{cases} 1 & \text{if } a \geq 21 \\ 0 & \text{if } a < 21 \end{cases}$ יד י' ורק על


חסר ההשדה של β_1

$$\overline{M}_a = \beta_0 + \beta_1 D_{age} + \beta_2 age + \epsilon$$



- הטיפול אינו מוקצה באופן אקראי! אנ ידעים מאיפה הוא בא.
- יחד עם זאת, הטיפול מקבע רק על ידי המשתנה "הרץ".
- שאלת הסיבתיות תלויה אפוא בשאלה האם הקשר בין המשתנה הטיפול לנתוצאות אכן נתפס על ידי רגרסיה עם "פיקוח" על גיל.
- כאן, אין ערך של משתנה הריצה בו אנו יכולים לצפות הן בתוצאות הטיפול והן בבקרה.
- תוקף ה- RD הוא דווקא בערכים בסביבת הפסקת הטיפול בו מופעלת. האופי המקומי של השוואת שכנות כאלה ניכר בתרשים.

זהירות!



איך נימנע
מטעויות כאלה?

- שתי אסטרטגיות מפחיתות את הסבירות לטעויות ב-RD אך אף אחת מהן איננה מספקת ביטוח מושלם!
- 1. מלכתחילה, לאמוד מודל לא ליניארי – בשיעור אחר
- 2. להתמקד בתצפיות הקרובות לסף


2. להתמקד בתצפיות
הקרובות לסף


- ככל שמתקרבים ל"נקודת האפס" – לסף – בעיית זיהוי "הקפיצה" מתגודדת לא ליניאריות ויורדת. עבור הנקודות הקרובות לנקודות הסף בעיה של תגודות לא ליניאריות לא מדאיגה אותנו.
- כלומר, להשוות בין ממוצעים בחלון צר בדיוק מימין ומשמאל לנקודת הסף
- החיסרון: אם החלון צר מדי, לא יהיו מספיק תצפיות כדי שהאומדן יהיה מדויק מספיק
- כלומר, trade off בין הימנעות מהטיה על ידי הצרת החלון לבין עליה בשונות כתוצאה מזריקת נתונים, צריך להגיע לגודל חלון אופטימלי
- גודל החלון h נקרא bandwidth
- איך בדיוק לבחור...? ספרות עניפה

$$\bar{M}_h = \beta_0 + \beta_1 D_{age} + \beta_2 age + \epsilon$$


In a sample such that $age - b \leq age \leq a_0 + age$


Fuzzy RD






Fuzzy RD






Peer effects
in the past




Peer effect
today

Fuzzy RD Is IV

$$y_i = \theta_0 + \theta_1 \bar{X}_{(i)} + \theta_2 X_i + u_i$$



$$y_i = \alpha_0 + \rho D_i + \beta_0 R_i + e_{0i}$$



$$\bar{X}_{(i)} = \alpha_1 + \psi D_i + \beta_1 R_i + e_{1i}$$

$$y_i = \alpha_2 + \lambda \bar{X}_{(i)} + \beta_2 R_i + e_{2i}$$

תרגיל 7

• בניית מודל

- החוקר משהשאלה הקודמת רוצה לבנות מודל שיסביר את השכר על ידי השכלה בצורה הטובה ביותר. הוא חושב שאת התשואה להשכלה יש למדוד באחוזים – כלומר, יש למצוא את אחוז התשואה בשכר לכל שנת לימוד. בנוסף, הוא מאמין כי מסיבות שאינן קשורות לרמת השכלה – נשים מרוויחות פחות מגברים, והתשואה שלהן להשכלה – האחוז שבו יעלה שכרן לכל שנת לימוד – שונה משל גברים גם כן. כמו כן הוא מאמין כי קשרים חברתיים משפיעים גם הם על ההשכלה שאדם רוכש – אדם שיש לו קשרים חברתיים טובים ומגוונים – מכיר יותר מקומות ואפשרויות ומגלה יותר סקרנות, מצד שני – "יותר מידי" קשרים חברתיים מונעים ממנו להתרכז במטרה. לבסוף, הוא רוצה לפקח גם על "הכשרון" של אדם – אותו הוא מקווה לייצג על ידי ציון IQ שלו

- כתבו את המודל שהחוקר רוצה לאמוד על ידי שימוש במשתנים הבאים:
Wage - שכר של פרט במדגם

Female – משתנה דמי ששווה 1 אם הפרט במדגם הוא אישה ו0 אחרת

Educ – מספר השנים שהפרט למד

IQ - ציון IQ של הפרט


Friends - מספר החברים הטובים של הפרט

הקדמה




דוגמא

- נניח שיש לנו נתונים שהוגרלו מתוך המודל הבא:
 $y = 1 + 0.5x + 4x^2 + N(0,1)$



Under/over fitting

- נבח שאנחנו מחליטים לאמוד קו ישר. זה יהיה underfitting כי אנחנו לא ממדלים את הגורם הרלוונטי - בירוק
- לחילופין, אנחנו יכולים לאמוד פולינום מדרגה 6 זה יהיה overfitting, מכיוון שהגורמים: x^0 , x^1 , x^2 לא הכרחיים ולא חלק מהמודל המקורי - בכחול
- אנחנו ממדלים פה רעש!



Overfitting

- אם אנחנו כוללים יותר מידע משתנים מסבירים ברגסיה, כולל כאלה שלא קשורים למשתנה התלוי, אנחנו עושים overfitting
- השלכות אפשריות:
 - המודל הנאמד לא יהיה טוב לחיזוי של תצפית חדשה, הטעות נאמדת באמידת חסר
 - המודל מורכב מדי, אנחנו ממדלים "רעש" שלא יהיה רלוונטי במדגם אחר
 - השונות של אומדן הרגרסיה עולה

Underfitting

- אם אנחנו כוללים פחות מידע משתנים מסבירים במודל, ומשאירים בחוץ משתנים שיכולים להסביר את המשתנה התלוי אנחנו עושים underfitting
- השלכות אפשריות:
 - המודל הנאמד לא יהיה טוב לחיזוי של תצפית חדשה, האומדים יהיו מוטים
 - האומדים יהיו מוטים!
 - האומדן לשונות הטעות יהיה גדול מדי

סדרות עיתיות



שאלה



- אנחנו רוצים לחזות את מדד תל אביב 125 על סמך נתוני עבר
- רגרסיה? ערך המדד – משתנה תלוי, יום/חודש/עונה- משתנה בלתי תלוי
- האמנם?


	A	B	C
1	חודש	מדד	
2	12/12/2021	1993.87	
3	15/12/2021	1995.66	
4	14/12/2021	1969.81	
5	11/12/2021	1974.27	
6	12/12/2021	1980.45	
7	09/12/2021	1995.28	
8	08/12/2021	1996.44	
9	07/12/2021	2004.81	
10	06/12/2021	1968.06	
11	05/12/2021	1951.68	
12	02/12/2021	1955.89	
13	01/12/2021	1980.61	
14	30/11/2021	1954.62	
15	29/11/2021	1969.16	
16	28/11/2021	1955.74	
17	25/11/2021	1987.15	
18	24/11/2021	1975.79	
19	23/11/2021	1984.3	

מבוא



- סדרות נתונים המתקבלות מתצפיות על תופעה מסוימת, לאורך זמן, נפוצות מאוד.
- לדוגמה, נתונים על תוצר שנתי, מדדי מחירים חודשיים, טמפרטורה יומית, פעילות חשמלית של המוח ועוד בתחומים רבים ומגוונים.
- המטרות העיקריות בניסוח סדרות עיתיות הן:
 - להבין ולמדל את המנגנון המקרי שייצר את הנתונים.
 - לחזות ערכים עתידיים של הסדרה ע"ס הנתונים שבידנו.

סדרות עיתיות – תיאור גרפי



סדרות עיתיות ותהליכים מקריים

- כאמור, כדי להבין את אופן היווצרות הנתונים בסדרות עיתיות, נצטרך להגדיר מבנה הסתברותי.
- נסמן ב- Y_t את ערך התצפית בזמן t ונניח כי Y_t הוא משתנה מקרי בעל התפלגות כלשהי.
- התכונה החשובה ביותר של מודלים של סדרות עיתיות היא קיום תלות בין תצפיות מזמנים שונים.
- לכן, עבור שני זמנים שונים t ו- s נאמר שלזוג המשתנים המקריים Y_t, Y_s יש התפלגות משותפת דו-מימדית כלשהי.

סדרות עיתיות ותהליכים מקריים

- באופן כללי, נאמר כי לסדרה בה אנו צופים $(Y_1, Y_2, \dots, Y_n)$ יש התפלגות משותפת רב-מימדית כלשהי וכי היא חלק מתוך סדרה אינסופית $\{Y_1, Y_2, \dots\}$ הנקראת תהליך מקרי.
- אנו לא נעסוק ישירות בהתפלגות הרב מימדית של הסדרה אלא נתרכז בתוחלות, שונויות ושונויות משותפות. (תחת הנחת התפלגות נורמלית, הנ"ל לבדם מגדירים את ההתפלגות הרב מימדית במלואה)

תוחלות, שונויות ושונותפחות



• לכל t נגדיר $\mu_t = E(Y_t)$

• לכל t ו- s נגדיר $\gamma_{t,s} = \text{cov}(Y_t, Y_s)$

• שימו לב: $\gamma_{t,t} = \text{cov}(Y_t, Y_t) = \text{var}(Y_t)$

• לכל t ו- s נגדיר $\rho_{t,s} = \frac{\text{cov}(Y_t, Y_s)}{\sqrt{\text{var}(Y_t) \text{var}(Y_s)}} = \frac{\gamma_{t,s}}{\sqrt{\gamma_{t,t} \gamma_{s,s}}}$

• $\rho_{t,s}$ הוא המתאם הסדרתי (autocorrelation) של הסדרה.

דוגמה - מהלך מקרי



• יהיו $\varepsilon_1, \varepsilon_2, \dots$ מ"מ ב"ת ש"ה עם תוחלת 0 ושונות σ^2 (הסדרה ε_t נקראת "רעש לבן")

• הסדרה תהיה מוגדרת כדלהלן:

$$Y_1 = \varepsilon_1$$

$$Y_2 = \varepsilon_1 + \varepsilon_2$$

$\vdots$

$$Y_t = \varepsilon_1 + \varepsilon_2 + \dots + \varepsilon_t$$

• או לחילופין: $Y_t = Y_{t-1} + \varepsilon_t$

דוגמה - מהלך מקרי



• משמעות המשתנה X_t היא "המרחק" שעבר ה"הולך" בזמן t ו- Y_t הוא המיקום של ה"הולך" בשלב t .

• במקרה זה:

• $\mu_t = E(Y_t) = E(\varepsilon_1 + \dots + \varepsilon_t) = 0$

• $\gamma_{t,t} = \text{var}(Y_t) = \text{var}(\varepsilon_1 + \dots + \varepsilon_t) = \text{var}(\varepsilon_1) + \dots + \text{var}(\varepsilon_t) = t\sigma^2$

דוגמה - מהלך מקרי

• ועבור $t \leq s$:

$$\begin{aligned}\gamma_{t,s} &= \text{cov}(Y_t, Y_s) = \text{cov}(\varepsilon_1 + \dots + \varepsilon_t, \varepsilon_1 + \dots + \varepsilon_t + \dots + \varepsilon_s) = \\ &= \underbrace{\text{cov}(\varepsilon_1, \varepsilon_1)}_{\sigma^2} + \cancel{\text{cov}(\varepsilon_1, \varepsilon_2)} + \dots + \cancel{\text{cov}(\varepsilon_1, \varepsilon_t)} + \dots + \cancel{\text{cov}(\varepsilon_1, \varepsilon_s)} + \\ &+ \cancel{\text{cov}(\varepsilon_2, \varepsilon_1)} + \underbrace{\text{cov}(\varepsilon_2, \varepsilon_2)}_{\sigma^2} + \dots + \cancel{\text{cov}(\varepsilon_2, \varepsilon_t)} + \dots + \cancel{\text{cov}(\varepsilon_2, \varepsilon_s)} + \\ &\quad \ddots \\ &+ \cancel{\text{cov}(\varepsilon_t, \varepsilon_1)} + \cancel{\text{cov}(\varepsilon_t, \varepsilon_2)} + \dots + \underbrace{\text{cov}(\varepsilon_t, \varepsilon_t)}_{\sigma^2} + \dots + \cancel{\text{cov}(\varepsilon_t, \varepsilon_s)} = \\ &= t\sigma^2\end{aligned}$$

דוגמה - מהלך מקרי

• ומכאן, עבור $t \leq s$:

$$\rho_{t,s} = \rho_{s,t} = \frac{\gamma_{t,s}}{\sqrt{\gamma_{t,t}\gamma_{s,s}}} = \frac{t\cancel{\sigma^2}}{\sqrt{t\cancel{\sigma^2}s\cancel{\sigma^2}}} = \sqrt{\frac{t}{s}}$$

• שימו לב, ככל שמדובר בנקודות זמן קרובות יותר, כך המתאם הסדרתי גבוה יותר.

דוגמה - מהלך מקרי