



מבוא

- בשבוע הקודם תארנו את המודל של רגרסיה לינארית פשוטה (משתנה מסביר אחד), מצאנו את אומדי OLS ואת התפלגותם.
- השבוע נלמד כיצד לבצע הסקה סטטיסטית על אומדי הרגרסיה ולאמוד את שונותם.
- בנוסף, נרחיב את המודל למספר רב של משתנים מסבירים.




רגרסיה לינארית פשוטה - המודל




רגרסיה לינארית פשוטה – משמעות המודל



רגרסיה לינארית פשוטה – משמעות המודל




רגרסיה לינארית פשוטה – משמעות המודל




- לא צופים ב- ϵ_1
- לא ידועה σ^2
- לא ידועים β_0, β_1


רגרסיה לינארית פשוטה – משמעות המודל



רגרסיה לינארית פשוטה – אמידה



רגרסיה לינארית פשוטה – אמידת ריבועים פחותים OLS



רגרסיה לינארית פשוטה – אמידת ריבועים פחותים OLS



- קצת אלגברה תביא אותנו לפתרון המשוואות:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{cov}(X, Y)}{\text{var}(X)} = r(X, Y) \frac{SD(Y)}{SD(X)}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

רגרסיה לינארית פשוטה – אמידת ריבועים פחותים OLS



:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{cov}(X, Y)}{\text{var}(X)} = r(X, Y) \frac{SD(Y)}{SD(X)}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

דוגמא מספרית



- מתווך דירות בתל אביב רצה לבדוק איך משפיע גודלה של דירה על המחיר שבו היא נמכרת. הוא הניח 2 הנחות מקדימות:
- א. רק גודל הדירה משפיע על מחיר הדירה באופן שיטתי. כל שאר הדברים המשפיעים על מחיר הדירה הם אקראיים ולא ניתנים לחיזוי
- ב. ההשפעה של גודל הדירה על מחיר הדירה היא ליניארית

דוגמא מספרית

- שתי ההנחות האלה מאפיינות את הקשר. אם נסמן את גודל הדירה ב- X ואת מחיר הדירה ב- Y , נוכל לכתוב באופן מתמטי כי:

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

- אחרי הגדרת המודל המתווך אסף נתונים על 6 דירות, שנמכרו בחודש האחרון באותו איזור.

דוגמא מספרית

- זהו המדגם של המתווך. במדגם יש 6 תצפיות. נוהגים להציג את המודל כאשר לכל משתנה נוסף אינדקס, האינדקס מייצג את מספר התצפית:

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

מספר הדירה מכירה	מספר הדירה מכירה	מספר הדירה מכירה
$X_1 = 70$	$Y_1 = 190$	1
$X_2 = 70$	$Y_2 = 210$	2
$X_3 = 80$	$Y_3 = 250$	3
$X_4 = 100$	$Y_4 = 290$	4
$X_5 = 120$	$Y_5 = 360$	5
$X_6 = 120$	$Y_6 = 380$	6

דוגמא מספרית

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{cov}(X, Y)}{\text{var}(X)} = r(X, Y) \frac{SD(Y)}{SD(X)}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

מספר הדירה מכירה	מספר הדירה מכירה	מספר הדירה מכירה
$X_1 = 70$	$Y_1 = 190$	1
$X_2 = 70$	$Y_2 = 210$	2
$X_3 = 80$	$Y_3 = 250$	3
$X_4 = 100$	$Y_4 = 290$	4
$X_5 = 120$	$Y_5 = 360$	5
$X_6 = 120$	$Y_6 = 380$	6

דוגמא מספרית

```
> beta_1=cov(x,y)/var(x)
> beta_1
[1] 3.292683
> beta_0=mean(y)-beta_1*mean(x)
> beta_0
[1] -27.31707
> |
```

```
> model <- lm(y ~ x)
> model
```

```
call:
lm(formula = y ~ x)
```

```
Coefficients:
(Intercept)          x
    -27.317         3.293
```

• הפירוט הבנוי של β_1 הוא

- הגדלה של הדרייה ב-10 מ"ר מתאמת עם עלייה של 3.29 אלף דולר במחיר
- הגדלה של הדרייה ב-1 מ"ר מתאמת עם עלייה של 3.29 אלף דולר במחיר
- הגדלה של הדרייה ב-1 מ"ר מתאמת עם עלייה של 3.29% במחיר
- לכל דריה יש מחיר בסיס של 3,290 דולר, והמחיר שלה משם ככל שהדריה גדולה יותר

גרסיה עם לוגים

- נסתכל על הרגרסיה הפשוטה הבאה:

$$\ln(Y) = \beta_0 + \beta_1 X + \epsilon$$

- בשביל מה הלוג?

$$\ln(y_2) = 5 + 0.03x_2 + \epsilon_2, \ln(y_1) = 5 + 0.03x_1 + \epsilon_1$$

$$\ln(y_2) - \ln(y_1) = 0.03 * (x_2 - x_1)$$

$$\ln\left(\frac{y_2}{y_1}\right) = 0.03(x_2 - x_1)$$

$$\frac{y_2}{y_1} = e^{0.03(x_2 - x_1)}$$

$$\frac{y_2}{y_1} = 1.03(x_2 - x_1)$$

מודל לוג לינארי

- מודל "חצי לוגריתמי"
- המודל: $\log(y) = a + \beta x + \epsilon$
- משמעות β במודל כזה היא שיעור השינוי השולי
- אם נגדיל את x ביחידה אחת, בכמה % ישתנה y

• הפירוט הבנוי של β_1 הוא

- הגדלה של הדריה ב-10 מ"ר מתאמת עם עלייה של 3.29 אלף דולר במחיר
- הגדלה של הדריה ב-1 מ"ר מתאמת עם עלייה של 3.29 אלף דולר במחיר
- הגדלה של הדריה ב-1 מ"ר מתאמת עם עלייה של 3.29% במחיר
- לכל דריה יש מחיר בסיס של 3,290 דולר, והמחיר שלה משם ככל שהדריה גדולה יותר







העולם כמעבדה




דוגמא 1


- בארצות הברית שיעור הסטודנטים שמסיימים תואר ראשון יורד בהדרגה.
- פוליטיקאים ומנתחי מדיניות מאשימים בכך את שכר הלימוד הגבוה ואת ההלוואות שדורשים סטודנטים לקחת.
- נתון: הסטודנטים שנשורים מהלימודים הם בחלקם הגדול – אלה שלקחו הלוואות גדולות
- האם חובות גורמים לחייבים לנשור?

דוגמא 1 – המשך Selection bias- הטיית בחירה




- איזה סוג של סטודנטים נוטים ללוות הלוואות גדולות?
- בדרך כלל סטודנטים שמגיעים ממשפחות מהמעמד הבינוני והנמוך מבחינה כלכלית.
- ידוע: תלמידים ממעמד כלכלי סוציאלי נמוך נוטים פחות לסיים את לימודיהם מחבריהם העשירים יותר, בלי קשר לשאלה אם לקחו הלוואה או לא.
- היו חשדניים!
- הטענה כי נטל החוב הוא הגורם להשלמה מבוססת רק על השוואה בין שיעורי השלמה בין בעלי חוב לבין אלה שאינם בעלי חוב. מכיוון שיש מתאם בין רקע משפחתי לבין חובות לקולג, הניגוד בין שיעורי ההשלמה בין אלו עם ובין אלו בלי חובות – הוא לא בר השוואה.
- הנחת *ceteris paribus* All things being equal

All things being equal – ceteris paribus



יש לכם עוד דוגמאות? תשלחו לי...



הקצאה מקרית

- הגדרה: הקצאה אקראית (רנדומלית) היא תהליך של הצבת נבדקי הניסוי בקבוצות טיפול או בקבוצות ביקורת באמצעות שימוש במקריות
- ההקצאה לאחת מן הקבוצות אינה תלויה במאפיינים של הפרטים
- בדוגמה שלנו?
- האם באופן הזה נוכל לטעון כי "שאר התנאים האחרים זהים?"
- לא, אבל באופן הזה נשיג את אותה התוצאה, כלומר, נוכל לתת להבדלים הנצפים פרשנות של סיבתיות, משום שמניפולציה מקרית עושה את שאר הדברים האחרים זהים
- **בממוצע** וכמו שנסביר נרחיב בחלק השני של השיעור **בממוצע** זה בדרך כלל מספיק.



דוגמה 2



- חוק בריאות חובה הוא אחד מהחוקים הכי נתונים במחלוקת אי פעם בארצות הברית. החוק הזה דורש מכל אזרח לקנות ביטוח בריאות, ומטיל קנס על מי שלא קנה מעצמו.
- השאלה המתבקשת: האם יש קשר סיבתי בין ביטוח בריאות (חובה) לבין בריאות.
- ארצות הברית מוציאה הכי הרבה מהתוצר שלה על ביטוח בריאות יותר מכל מדינה מפותחת אחרת, ובאופן מפתיע, עדיין, האמריקאים לא בהכרח בריאים יותר או בכלל. למשל, אמריקאים נוטים להשמנת יתר, והם מתים מהר יותר מאשר בני הדודים הקנדיים שלהם, שמוציאים על בריאות שני שלישי ממה שאמריקה מוציאה



Health Interview Survey (NHIS)
מדד בריאות 1-5

ממצאים ראשוניים

TABLE 1.1

Health and demographic characteristics of insured and uninsured couples in the NHIS

	Husbands			Wives		
	Some HI (1)	No HI (2)	Difference (3)	Some HI (4)	No HI (5)	Difference (6)
A. Health						
Health index	4.01 [.93]	3.70 [1.01]	.31 (.03)	4.02 [.92]	3.62 [1.01]	.39 (.04)

מה שלא סופר...


TABLE 1.1

Health and demographic characteristics of insured and uninsured couples in the NHIS

	Husbands			Wives		
	Some HI (1)	No HI (2)	Difference (3)	Some HI (4)	No HI (5)	Difference (6)
A. Health						
Health index	4.01 [.93]	3.70 [1.01]	.31 (.03)	4.02 [.92]	3.62 [1.01]	.39 (.04)
B. Characteristics						
Nonwhite	.36	.37	-.01 (.01)	.35	.37	-.02 (.01)
Age	41.98	41.26	2.71 (.29)	42.24	39.62	2.62 (.30)
Education	14.31	11.56	2.74 (.10)	14.44	11.80	2.64 (.11)
Family size	3.30	3.98	-.67 (.05)	3.49	3.93	-.43 (.05)
Employed	.92	.85	.07 (.01)	.77	.56	.21 (.02)
Family income	106,467	45,656	60,810 (1,555)	106,212	46,383	59,828 (1,496)
Sample size	8,114	1,281		8,264	1,331	

Notes: This table reports average characteristics for insured and uninsured married couples in the 2009 National Health Interview Survey (NHIS). Columns (1), (2), (4), and (5) show average characteristics of the group of individuals specified by the column heading. Columns (3) and (6)

אומדים הם משתנים מקריים





אמיתי או רק מזל ?



רגרסיה לינארית פשוטה – התפלגות האומדים



$$\hat{\beta}_1 \sim N\left(\beta_1, \text{var}(\hat{\beta}_1)\right) \quad \text{var}(\hat{\beta}_1) = \frac{\sigma^2}{n \text{var}(X)}$$

⇓

$$\frac{\hat{\beta}_1 - \beta_1}{\text{sd}(\hat{\beta}_1)} \sim N(0,1)$$

רגרסיה לינארית פשוטה – בדיקת השערות



- לאור ידיעתנו את התפלגות האומדים, נוכל לבצע בדיקת השערות, לדוגמה:

$$H_0 : \beta_1 = b$$

$$H_1 : \beta_1 \neq b$$

- לפי השערת ה-0 מתקיים:

$$Z = \frac{\hat{\beta}_1 - b}{\text{sd}(\hat{\beta}_1)} \sim N(0,1)$$

- ולכן אם $|Z| > Z_{1-\frac{\alpha}{2}}$ נדחה את השערת ה-0.

רגרסיה לינארית פשוטה – בדיקת השערות



- אבל יש בעיה אחת קטנה, כדי לחשב את $sd(\hat{\beta}_1)$ עלינו לדעת את ערכו של σ^2 ובד"כ הוא אינו ידוע.
- לכן עלינו לאמוד את $\sigma^2 = \text{var}(\varepsilon)$ ונעשה זאת ע"י:

$$\hat{\sigma}^2 = MSE = \frac{1}{n-2} \sum_{i=1}^n e_i^2$$

- ונגדיר:

$$se(\hat{\beta}_1) = \frac{MSE}{n \text{var}(X)}$$

רגרסיה לינארית פשוטה – בדיקת השערות



- ובדומה למה שראינו בשיעורים הקודמים נסתכל על הסטטיסטי:

$$T = \frac{\hat{\beta}_1 - b}{se(\hat{\beta}_1)} \sim t_{n-2}$$

- ולכן אם $|T| > t_{n-2, 1-\frac{\alpha}{2}}$ נדחה את השערת ה-0.

דוגמא מספרית

מספר תצפית	שנת הלידה	גובה
1	1972	1.70
2	1972	1.75
3	1972	1.78
4	1972	1.80
5	1972	1.82
6	1972	1.85
7	1972	1.88
8	1972	1.90
9	1972	1.92
10	1972	1.95



$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\text{cov}(X, Y)}{\text{var}(X)} = r(X, Y) \frac{SD(Y)}{SD(X)}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

דוגמא מספרית R

```
> summary(model)

Call:
lm(formula = y ~ x)

Residuals:
    1     2     3     4     5     6 
-13.171  6.829 13.902 -11.951  -7.805 12.195 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -27.3171    25.3397  -1.078  0.34169
x              3.2927     0.2647  12.441  0.00024 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 13.84 on 4 degrees of freedom
Multiple R-squared:  0.9748,    Adjusted R-squared:  0.9685 
F-statistic: 154.8 on 1 and 4 DF,  p-value: 0.00024
```

האם זה שווה? הקדמה לרגרסיה מרובה



ניסוח השאלה

- מה תלמיד מקולג' פרטי היה מפסיד אם הוא היה הולך לבית ספר ציבורי?
- השוואת רווחים בין תלמידים לשעבר בקולג פרטי וקולג ציבורי?
- הטיית בחירה !!!
- יש בידינו נתונים שנוצרו על ידי הגשות בקשה להתקבל, החלטות שקיבלו סטודנטים ואוניברסיטאות מסוגים שונים
- האם ניתן יהיה להשתמש בנתונים האלה כדי לנסות לחקות ניסוי אקראי?
- מושלם זה לא יהיה, אבל אולי נוכל להתקרב
- המפתח: החלטות ובחירות רבות, כולל החלטות הקשורות להשתתפות במכללה, כוללות מידה מסוימת של וריאציה נובעת משיקולים כספיים, נסיבות אישיות ותזמון.

כלומר,

- לנצל סרנדיפיות במדגם של מועמדים על הפרק, שיכולים בקלות ללכת בדרך זו או אחרת
- האם מישהו שהתקבל להרווארד באמת הולך לבית הספר הממלכתי המקומי במקום זאת?

האם מדגם גדול מספיק לנו?

- לא!! מדגם גדול לא יעזור לנו להימנע מהטיית בחירה
- הצעד הראשון והכי חשוב במאמץ שלנו לבודד את המרכיב של בחירת בית הספר ברווחים עתידיים, **הוא להחזיק קבוע את רוב ההבדלים הנצפים החשובים** בין סטודנטים שבחרו ללכת לבית ספר בפרטי לבין אלו שבחרו ללכת לבית ספר ציבורי. בדרך הזו, אנחנו מקווים, אם כי לא נוכל להבטיח, שאנחנו עושים את "כל התנאים האחרים זהים"

האם מדגם גדול מספיק לנו?

- נניח! מה שחשוב לשכר – בית הספר אליו התלמיד בחר ללכת וציון הSAT
- נניח שני סטודנטים, עמי ותמי, לשניהם ציון SAT זהה, עמי הלך לבית ספר ציבורי ותמי לבית ספר פרטי, אנחנו מתחילים בלהשוות את הרווחים של כל אחד מהם. מכיוון שאנחנו מניחים שכל מה שחשוב לרווחים זה בית ספר וציון הSAT אז ההשוואה בין שני הסטודנטים שלנו היא בעצם תחת ההנחה שכל התנאים האחרים שווים.
- החיים הרבה יותר מורכבים... למשל... ההבדל המגדרי, מצב סוציאקונומי, מוטיבציה, כישורן
- העובדה שעמי מרוויח 20% יותר מתמי יכולה להיות בגלל שלו יש חינוך יותר טוב אבל באותה המידה היא יכולה להיות קשורה לפער בין גברים לנשים בשכר שנוצר בגלל סיבות אחרות.
- אנחנו רוצים לבודד את האפקט של עמי מאותן סיבות אחרות. זה יהיה קל אם הסיבות האחרות האלו יהיו רק עניין מגדרי. נחליף את עמי עם תלמידה מאוורד, חנה, עם אותו ציון פסיכומטרי. ונשווה בין חנה לבין תמי
- בגלל שאנחנו רוצים לבצע הכללה, נחפש אחרי הרבה נשים משני בתי הספר, עם אותו הציון

משתנים מפקחים

- הוא משתנה חיצוני המשפיע הן על המשתנה התלוי והן על המשתנה הבלתי תלוי באופן דומה, ולפיכך עלול להוביל למסקנה מוטעית על הקשר האמיתי ביניהם. השפעה כזו יכולה להיות חלקית או מלאה.
- בסיפור שלנו (קשר בין שכר וסוג השכלה): המפקחים הם: מגדר וציון SAT

אבל יש הרבה "סיבות אחרות"...

Student	Private			Public		1994 earnings
	Ivy	Leafy	Smart	All State	Tall State	
1	Reject	Admit		Admit		110,000
2	Reject	Admit		Admit		100,000
3	Reject	Admit		Admit		110,000
4	Admit			Admit	Admit	60,000
5	Admit			Admit	Admit	30,000
6		Admit			Admit	115,000
7		Admit			Admit	75,000
8	Reject			Admit	Admit	90,000
9	Reject			Admit	Admit	60,000

decisions are highlighted in gray.

- ברגדיל ואון קהרר העל קצור דרך חכם ומשכנע. במקום לזהות את כל מה שעשוי להיות חשוב לבודדות בית ספר ורווחים עתידיים, הם עוברים עם מודל מרכזי אחר: מאפיין המכללת אליקן פט והתקבל סטודנטים.
- מערך נתונים גדול בשם College and Beyond (C&B).
- The college matching matrix

$$average\ private - average\ public = 20000\$!!!!$$

חלוקת הסטודנטים לקבוצות "דומות"



$$\frac{110,000 + 100,000}{2} - 110,000 = -5000$$

$$60,000 - 30,000 = 30,000$$

$$\frac{30000 - 5000}{2} = 12,500$$

$$\frac{3}{5} \cdot -5000 + \frac{2}{5} \cdot 30000 = 9000$$

Applicant group	Student	Private			Public		1994 earnings
		Ivy	Leafy	Smart	All State	Tall State	
A	1	Reject	Admit		Admit		110,000
	2	Reject	Admit		Admit		100,000
	3	Reject	Admit		Admit		110,000
B	4	Admit			Admit	Admit	60,000
	5	Admit			Admit	Admit	30,000
C	6		Admit			Admit	115,000
	7		Admit			Admit	75,000
D	8	Reject			Admit	Admit	90,000
	9	Reject			Admit	Admit	60,000

Note: Enrollment decisions are highlighted in gray.

רגרסיה

- אומדי רגרסיה (כבר נראה מה זה...) הם ממוצעים משוקללים של השוואות תואמות מרובות מהסוג שבנינו בדוגמא האחרונה
- מרכיבי הרגרסיה:
 - המשתנה התלוי – הרווחים של הסטודנט בהמשך חייו Y_i
 - משתנה הטיפול – משתנה דמה המציין אם הסטודנט למד במוסד פרטי או ציבורי P_i
 - משתני בקרה/משתנים מפקחים – משתנים המזהים קבוצות של בתי ספר אליהם פנו והתקבלו התלמידים A_i
- מודל הרגרסיה בהקשר זה הוא משוואה המקשרת בין משתנה הטיפול למשתנה התלוי תוך החזקת משתני הבקרה קבועים על ידי הכללתם במודל:

$$Y_i = \alpha + \beta \cdot P_i + \gamma \cdot A_i + \epsilon_i$$

הערה חשובה

- ההבחנה בין משתנה הטיפול, P_i , לבין משתנה הבקרה, A_i , במשוואת הרגרסיה היא מושגית, לא פורמלית. אין במשוואה זו שום דבר שיצביע על איזה מן המשתנים הם משתני טיפול או בקרה. שאלת המחקר והאסטרטגיה האמפירית מצדיקות את בחירת המשתנים וקובעות את התפקידים שהם ממלאים.

$$Y_i = \alpha + \beta \cdot P_i + \gamma \cdot A_i + \epsilon_i$$

משמעות הפרמטרים

$$Y_i = \alpha + \beta \cdot P_i + \gamma \cdot A_i + \epsilon_i$$

$$\begin{aligned}\alpha &= 40,000 \\ \beta &= 10,000 \\ \gamma &= 60,000.\end{aligned}$$

- החותך - α "אלפא"
- ההשפעה "האמיתית" של הטיפול, β ("בטא");
- ההשפעה של להיות תלמיד קבוצה A , γ ("גמא").
- השארית, השגיאה ϵ_i ("אפסילון")
- השארית היא ההבדל בין ה- Y_i הנצפה לבין החזוי על פי המודל:
- $\hat{Y}_i = \alpha + \beta \cdot P_i + \gamma \cdot A_i$
- כלומר, $\epsilon_i = Y_i - \hat{Y}_i = Y_i - (\alpha + \beta \cdot P_i + \gamma \cdot A_i)$
- Ols - ordinary least squares

Private school effects: Barron's matches

	No selection controls			Selection controls		
	(1)	(2)	(3)	(4)	(5)	(6)
Private school	.111	.091	.084	.007	.003	.011
	(.015)	(.012)	(.014)	(.010)	(.010)	(.012)
Over SAT score + 100	.048	.016		.013	.001	
	(.007)	(.007)		(.007)	(.007)	
Log parental income	.219			.190		
	(.022)			(.023)		
Female	-.403			-.391		
	(.018)			(.018)		
Black	.003			-.000		
	(.041)			(.042)		
Hispanic	.062			.032		
	(.072)			(.070)		
Asian	.170			.141		
	(.074)			(.069)		
Other/race mix	-.074			-.079		
	(.117)			(.116)		
High school top 10%	.001			.002		
	(.027)			(.028)		
High school rank mixing	.019			.011		
	(.033)			(.037)		
Adverse	.113			.111		
	(.031)			(.027)		
Selectivity-group dummies	No	No	No	Yes	Yes	Yes

Notes: This table reports estimates of the effect of attending a private college or university on earnings. Each column reports coefficients from a regression of log earnings on a dummy for attending a private institution and controls. The results in columns (4)-(6) are from models that include applicant selectivity-group dummies. The sample size is 5,983. Standard errors are reported in parentheses.

גרסיה לינארית מרובה – המודל

- לכל תצפית $i = 1, \dots, n$ מתקיים:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \varepsilon_i$$

- וכן לכל $i, j, \varepsilon_i, X_{ji}$ ב"ת ומתקיים:

$$\varepsilon_i \sim N(0, \sigma^2) \text{ ב"ת}$$

- והתפלגות X_{ji} התפלגות כלשהי.

- אנחנו צופים רק ב- $X_{1i}, \dots, X_{ki}, Y_i$ אך אין יכולת לצפות ב- ε_i

גרסיה לינארית מרובה – משמעות המודל

- לכל תצפית $i = 1, \dots, n$ ניתן להסביר את ערכו של Y ע"י פונקציה ליניארית של ערכם של $X_1, \dots, X_k$ בתוספת "טעות" המבטאת את כל יתר הגורמים הנוספים המשפיעים על Y מלבד $X_1, \dots, X_k$.

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \varepsilon_i$$

- בנוסף אנחנו מניחים כי אין תלות בין $X_1, \dots, X_k$ לבין יתר הגורמים המשפיעים על הטעות.
- משמעות הפרמטר β_j הוא השינוי ב- Y ליח' שינוי של X_j כשיתר המשתנים המסבירים והטעות ללא שינוי.

רגרסיה לינארית מרובה – אמידת ריבועים פחותים OLS



- נחשב את האומדים ע"י:

$$\arg \min_{\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k} \sum_{i=1}^n \left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i) \right]^2 = \arg \min_{\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k} SSE$$

- נגזרת ראשונה תביא אותנו למשוואות:

$$\frac{\partial SSE}{\partial \hat{\beta}_0} = \sum_{i=1}^n -2 \left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_k x_{ki}) \right] = 0 \Rightarrow \sum_{i=1}^n e_i = 0$$

- ולכל j :

$$\frac{\partial SSE}{\partial \hat{\beta}_j} = \sum_{i=1}^n -2 x_{ji} \left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \dots + \hat{\beta}_k x_{ki}) \right] = 0 \Rightarrow \sum_{i=1}^n x_{ji} e_i = 0$$

רגרסיה לינארית מרובה – אמידת ריבועים פחותים OLS



- בניגוד לרגרסיה ליניארית פשוטה, כאן אין ביטוי "יפה" לחישוב האומדים ולכן נעזר בתוכנות סטטיסטיות לאמידת המקדמים.

- למרות זאת ניתן להראות כי:

$$\hat{\beta}_j = \frac{\sum_{i=1}^n e_{(j)i} (Y_i - \bar{Y})}{\sum_{i=1}^n e_{(j)i}^2} = \frac{\text{cov}(e_{(j)}, Y)}{\text{var}(e_{(j)})}$$

- כאשר $e_{(j)}$ הן השאריות מהרגרסיה של X_j על יתר המשתנים המסבירים.


הרחבה



$$y = \alpha + \beta x + \gamma z + \epsilon$$

$$x = \pi_0 + \pi_1 z + \epsilon_x$$

$$y = \alpha + \beta \epsilon_x + \epsilon$$



רגרסיה לינארית מרובה – אמידת ריבועים פחותים OLS



- בדומה למה שנעשה ברגרסיה לינארית פשוטה, ניתן להראות כי אומדים אלה הם גם אומדי מומנטים ואומדי נראות מרבית.

רגרסיה לינארית מרובה – התפלגות האומדים



- בדומה למה שנעשה עבור רגרסיה לינארית פשוטה, ניתן להראות כי:
$$\hat{\beta}_j \sim N\left(\beta_j, \frac{\sigma^2}{n \text{var}(X)(1-R_{(j)}^2)}\right)$$
- כאשר $R_{(j)}^2$ הוא ה- R^2 המתקבל מרגרסיה של X_j על יתר המשתנים המסבירים.
- האומד חסר הטיה
- שונות האומד פוחתת עם גודל המדגם, עם השונות של X ועם אחוז השונות הלא מוסברת של X_j ע"י יתר המשתנים המסבירים.

רגרסיה לינארית מרובה – התפלגות האומדים



- גם כאן σ^2 לא ידועה ולכן נאלץ לאמוד אותה ע"י:

$$\hat{\sigma}^2 = MSE = \frac{1}{n-k-1} \sum_{i=1}^n e_i^2$$

- ונסמן $se(\hat{\beta}_j)$ את סטיית התקן הנאמדת של $\hat{\beta}_j$.

גרסיה לינארית מרובה – בדיקת השערות



- גם כאן ע"מ לבדוק השערות מהסוג:

$$H_0: \beta_j = b$$

$$H_1: \beta_j \neq b$$

- נעשה זאת באמצעות הסטטיסטי:

$$T = \frac{\hat{\beta}_j - b}{se(\hat{\beta}_j)} \sim t_{n-k-1}$$

- כך שאם $|T| > t_{n-k-1, 1-\frac{\alpha}{2}}$ נדחה את השערת ה-0.

דוגמא מספרית



```
install.packages("datarium")
data("marketing", package = "datarium")
head(marketing, 4)
cor(marketing$sales, marketing$youtube)
plot(marketing$youtube, marketing$sales)
model <- lm(sales ~ youtube+facebook+newspaper, data = marketing)
summary(model)
```

> model

Call:
lm(formula = sales ~ youtube + facebook + newspaper, data = marketing)

Coefficients:
(Intercept) youtube facebook newspaper
3.526667 0.045765 0.188530 -0.001037

> summary(model)

Call:
lm(formula = sales ~ youtube + facebook + newspaper, data = marketing)

Residuals:
Min 1Q Median 3Q Max
-10.5932 -1.0690 0.2902 1.4272 3.3951

Coefficients:
 Estimate Std. Error t value Pr(>|t|)
(Intercept) 3.526667 0.374290 9.422 <2e-16
youtube 0.045765 0.001395 32.809 <2e-16
facebook 0.188530 0.008611 21.893 <2e-16
newspaper -0.001037 0.005871 -0.177 0.86

(Intercept) ***
youtube ***
facebook ***
newspaper

Signif. codes:
0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.023 on 196 degrees of freedom
Multiple R-squared: 0.8972, Adjusted R-squared: 0.8956
F-statistic: 570.3 on 3 and 196 DF, p-value: < 2.2e-16

רגרסיה לינארית מרובה – בדיקת השערות מורכבות



- השערה מורכבת היא השערה על יותר מפרמטר אחד, למשל:
 $H_0: \beta_1 = b_1, \beta_2 = b_2$
 H_1 : אחרת
- אפשרות אחת היא לבצע 2 מבחני T אך אז לא ממש ברור מהי רמת המובהקות של המבחן.
- הפתרון: מבחן F .

רגרסיה לינארית מרובה – בדיקת השערות מורכבות



- על מנת לבצע מבחן F נאמוד 2 רגרסיות, אחת רגרסיה "מוגבלת" המניחה שהשערת ה-0 נכונה, ואחת "לא מוגבלת" שלא מניחה דבר (הרגרסיה המקורית).
- כך למשל, הרגרסיה ה"מוגבלת" של ההשערות מהשקופית הקודמת היא:
$$Y_i = \beta_0 + b_1 X_{1i} + b_2 X_{2i} + \beta_3 X_{3i} \cdots + \beta_k X_{ki} + \varepsilon_i$$
- ומכיון ש- b_1, b_2 אינם פרמטרים אלא מספרים קבועים, נאמוד את הרגרסיה:
$$Y_i - b_1 X_{1i} - b_2 X_{2i} = \beta_0 + \beta_3 X_{3i} \cdots + \beta_k X_{ki} + \varepsilon_i$$

רגרסיה לינארית מרובה – בדיקת השערות מורכבות



- עבור כל אחת משתי הרגרסיות ניתן לחשב את SSE ונסמן ב- SSE_{UR} עבור הרגרסיה הלא מוגבלת וב- SSE_R עבור הרגרסיה המוגבלת.
- שימו לב כי חייב להתקיים: $SSE_R \geq SSE_{UR}$
- סטטיסטי F יהיה:
$$F = \frac{SSE_R - SSE_{UR} / q}{SSE_{UR} / (n - k - 1)} \sim F_{q, n-k-1}$$
- כאשר q הוא מספר האילוצים תחת השערת ה-0

רגרסיה לינארית מרובה – בדיקת השערות מורכבות



- ככל שהשערת ה-0 יותר "נכונה" כך נצפה לערך F נמוך יותר.

- ולכן, נדחה את השערת ה-0 אם $F > F_{q,n-k-1,1-\alpha}$

$$F = \frac{SSE_R - SSE_{UR} / q}{SSE_{UR} / (n - k - 1)} \sim F_{q,n-k-1}$$
