



רגרסיה לינארית מרובה – המודל



- לכל תצפית $i = 1, \dots, n$ מתקיים:
$$Y_i = \beta_0 + \sum_{j=1}^k \beta_j X_{ji} + \varepsilon_i$$
- וכן לכל $X_{ji}, \varepsilon_i, j, i$ ב"ת ומתקיים:
$$\varepsilon_i \sim N(0, \sigma^2) \text{ ב"ת}$$
- והתפלגות X_{ji} התפלגות כלשהי.
- אנחנו צופים רק ב- $X_1, \dots, X_k, Y_i$ אך אין יכולת לצפות ב- ε_i

רגרסיה לינארית מרובה – פירוט הנחות המודל



- נהוג לפרט את הנחות המודל באופן הבא:
- 1. המודל לינארי בפרמטרים
- 2. המדגם מקרי
- 3. אין תלות לינארית מלאה בין המשתנים המסבירים
- 4. הנחת התוחלת המותנה: $E(\varepsilon | X_1, \dots, X_k) = 0$
- 5. הומוסקדסטיות: $\text{var}(\varepsilon | X_1, \dots, X_k) = \sigma^2$
- 6. הנחת הנורמליות: $\varepsilon \sim N$

הנחת הלינאריות

- על המודל להיות לינארי בפרמטרים, אך אין פירוש הדבר שהמודל בהכרח לינארי במשתנים.
- נתבונן למשל במודל הבא המתאר קשר בין כמות ההון וכמות העבודה, והתוצר השנתי ע"י פונקציית קוב-דוגלס:

$$Y = AK^\alpha L^\beta e^\varepsilon$$

- לכאורה, המודל אינו לינארי בפרמטרים A, α, β אך ע"י טרנספורמציות לוג נקבל את המודל:

הנחת הלינאריות

$$\log Y = \log A + \alpha \log K + \beta \log L + \varepsilon$$

$\beta_0 \quad \beta_1 \quad \beta_2$

- קיבלנו מודל לינארי בפרמטרים, אך לא לינארי במשתנים.
- משמעות הדבר היא, שבבואנו לבדוק את הקשר בין תשומות הון ועבודה לתוצר, תחת הנחת פונקציית ייצור קוב-דוגלס, עלינו לבצע קודם טרנספורמציות לוג על הנתונים, אחרת נקבל אומדים חסרי משמעות.


מודל ריבועי

- אחת התוצאות של מודל לינארי, היא השפעה שולית קבועה של המשתנים.
- אך לעיתים, ידוע כי ההשפעה השולית אינה קבועה אלא עולה או יורדת בערכו של המשתנה.
- במקרים כאלה נוכל לשקול את המודל הבא:

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$$

מודל זה מתאר קשר ריבועי בין X ו- Y .

מודל ריבועי



- בגרף מתוארת השפעה שולית עולה.
- בתחילה ההשפעה שלילית, אך היא הולכת ועולה ונהיית לבסוף חיובית.

- במקרה הריבועי ההשפעה השולית היא:
$$\frac{\partial Y}{\partial X} = \beta_1 + 2\beta_2 X$$
- והיא עולה (יורדת) אם β_2 חיובי (שלילי).

מודל ריבועי

- שימו לב שהמודל הנ"ל מקיים את הנחת הלינאריות, כאשר X הוא המשתנה הראשון ו- X^2 הוא המשתנה השני.

- שימו לב שהנחה מס' 3 לא מופרת שכן
 $|Corr(X, X^2)| \neq 1$

דוגמא

- בהמשך לנתונים של ה-NBA נאמוד מודל שמסביר את מספר הנקודות במשחק (*points*) באמצעות שנים בליגה (*exper*), גיל (*age*), ושנות משחק בקולג' (*coll*). בנוסף, נכניס את המשתנה *exper* בריבוע.
- כאשר מחזיקים את הגיל (*age*), ואת שנות המשחק בקולג' (*coll*) קבוע, אחרי כמה שנים בליגה (או: עבור איזה ערך של *exper*) שנה נוספת למעשה מקטינה את מספר הנקודות במשחק? האם זה הגיוני?

דוגמא

```
> model3nba
```

```
call:
lm(formula = points ~ exper + age + coll + exper2, data = nba)
```

```
Coefficients:
(Intercept)      exper         age         coll      exper2
  34.98355      2.33702     -1.06174     -1.27589     -0.07577
```

משתני דמי

- משתנה דמי הוא משתנה המקבל את הערכים 0 ו-1 בלבד.
- משמעות הערך 1 היא קיום תכונה מסוימת והערך 0 מסמן אי-קיום התכונה.
- לדוגמה, המודל המתאר את הקשר בין שכר להשכלה

$$wage = \beta_0 + \beta_1 F + \beta_2 educ + \varepsilon$$


$$F = \begin{cases} 1 & \text{if } i \text{ is female} \\ 0 & \text{if } i \text{ is male} \end{cases} \quad \bullet \text{ כאשר:}$$

משתני דמי - דוגמה

- במקרה זה, נקבל שני מודלים שונים, אחד עבור גברים, ואחד עבור נשים:

$$wage = \beta_0 + \beta_1 \cdot 0 + \beta_2 educ + \varepsilon \quad \bullet \text{ גברים:}$$

$$wage = (\beta_0 + \beta_1 \cdot 1) + \beta_2 educ + \varepsilon \quad \bullet \text{ נשים:}$$



משתני דמי - דוגמה

- נשים לב שבמודל הנ"ל קיימת הנחה שההבדל בין גברים לנשים הוא רק בחותך, ואילו השיפוע בשני המינים זהה.
- משמעות הדבר היא הבדל קבוע בשכר גברים ונשים ללא תלות בהשכלה.
- כמו כן, ע"פ המודל, תוספת השכר בגין כל שנת לימוד נוספת זהה בין גברים לנשים.
- הנחה זו עלולה להיות לא נכונה וכדי לאפשר הבדל גם בשיפוע, עלינו להוסיף משתנה נוסף.

משתני דמי - אינטראקציה

- ע"מ לאפשר הבדל גם בשיפוע עלינו להוסיף משתנה אינטראקציה והמודל יהיה:

$$wage = \beta_0 + \beta_1 F + \beta_2 educ + \beta_3 F \cdot educ + \varepsilon$$

- כך ש:

- עבור גברים:


$$wage = \beta_0 + \cancel{\beta_1 \cdot 1} + \beta_2 educ + \cancel{\beta_3 \cdot 0 \cdot educ} + \varepsilon$$

- ועבור נשים:

$$wage = (\beta_0 + \beta_1 \cdot 1) + (\beta_2 + \beta_3 \cdot 1) \cdot educ + \varepsilon$$

משתני דמי - אינטראקציה

- במקרה זה, נקבל שני קווים בעלי חותך ושיפוע שונים:



- ציור זה מתייחס למקרה שבו $\beta_1 > 0, \beta_3 < 0$.

משתני דמי - אינטראקציה

- שימו לב שתמיד נוכל לבדוק את נחיצות האינטראקציה ע"י בדיקת ההשערה: $H_0: \beta_3 = 0$
- וכדי לבדוק האם קיים הבדל כלשהו בין גברים לנשים במשוואת השכר, נבדוק את ההשערה המורכבת: $H_0: \beta_1 = \beta_3 = 0$



דוגמא

- הגרסיה הבאה התקבלה באמצעות OLS תוך שימוש בנתונים מתוך קובץ GPA2RAW:

$$\hat{sat} = 1,028.1 + 19.3hsizex - 2.19hsizex^2 - 45.09female - 169.81black + 62.31female \cdot black$$

(6.29) (3.83) (-.53) (4.29) (12.71) (18.15)

$n = 1,191, R^2 = .0493$

- המשתנה sat הוא ציון ה-SAT, hsize הוא גודל הכיתה של התלמיד בשנה האחרונה של התיכון (במאות), female הוא משתנה דמי למגדר ו-black הוא משתנה דמי לגזע השווה ל-1 עבור שחורים ו-0 אחרת



דוגמא

- כאשר hsize מוחזק קבוע, מהו ההבדל הנאמד בין ציוני ה-SAT של נשים לא שחורות לזה של גברים לא שחורים? עד כמה מובהק הבדל זה מבחינה סטטיסטית?
- תשובה:
- נשים לא שחורות: $female = 1, black = 0$
- גברים לא שחורים: $female = 0, black = 0$
- כלומר, הפער הזה נמדד על ידי המקדם של female שהוא -45.09
- ה-t statistic שווה ל-10.51 שזה כמובן מובהק

$$\hat{sat} = 1,028.1 + 19.3hsizex - 2.19hsizex^2 - 45.09female - 169.81black + 62.31female \cdot black$$

(6.29) (3.83) (-.53) (4.29) (12.71) (18.15)

$n = 1,191, R^2 = .0493$



דוגמא

$$\hat{sat} = 1,028.1 + 19.3 \text{size} - 2.19 \text{size}^2 - 45.09 \text{female} - 169.81 \text{black} + 62.31 \text{female} \cdot \text{black}$$

(6.29) (3.83) (53) (4.29) (12.71) (18.15)

$n = 1,191, R^2 = .0493$

- מהו ההבדל הנאמד בין ציוני ה-SAT של גברים לא שחורים לזה של גברים שחורים? בדקו את השערת האפס שאין הבדל בין הציונים שלהם כנגד ההשערה האלטרנטיבית שיש הבדל

תשובה:

- גברים לא שחורים: $\text{female} = 0 \text{ black} = 0$
- גברים שחורים $\text{female} = 0 \text{ black} = 1$
- כלומר, הפער הזה נמדד על ידי המקדם של black – כמעט 170 נקודות פער בציון
- ה- t statistic גדול מ-13, כלומר, מובהק

דוגמא

$$\hat{sat} = 1,028.1 + 19.3 \text{size} - 2.19 \text{size}^2 - 45.09 \text{female} - 169.81 \text{black} + 62.31 \text{female} \cdot \text{black}$$

(6.29) (3.83) (53) (4.29) (12.71) (18.15)

$n = 1,191, R^2 = .0493$

- מהו ההבדל הנאמד בין ציוני ה-SAT של נשים לא שחורות לזה של נשים שחורות? מה אתם צריכים כדי לבדוק אם הבדל זה מובהק מבחינה סטטיסטית?

תשובה:

- נשים לא שחורות $\text{female} = 1 \text{ black} = 0$
- נשים שחורות $\text{female} = 1 \text{ black} = 1$
- כלומר הפער הזה נמדד על ידי סכום המקדמים של black ו- $\text{female} \cdot \text{black}$: $-169.81 + 62.31 = -107.50$
- מהנתונים שיש לנו, והצורה הספיציפית הזו של הרגרסיה – לא ניתן לחשב את ה- T סטטיסטי

משתנים קטגוריאלים

- לעיתים קיים משתנה שמי, שעשוי לקבל יותר משני ערכים אפשריים כמו במקרה של משתנה דמי.
- במקרה זה, נצטרך "לקודד" את ערכי המשתנה בעזרת כמה משתני דמי.
- לדוגמה, נניח שאין לנו נתונים על שנות הלימוד, אלה רק על סוג ההשכלה שיכולה להיות, יסודית, תיכונית או אקדמית.
- במקרה זה ניתן ליצור 3 משתני דמי, אחד עבור כל סוג השכלה: H , E , ו- A המקבלים את הערך 1 עבור השכלה יסודית, תיכונית ואקדמית בהתאמה.

משתנים קטגוריאליים - דוגמה

- במידה ונכניס את כל שלושת המשתנים לרגרסיה, תהיה הפרה של הנחה מס' 3 שכן תמיד מתקיים:

$$E + H + A = 1$$

- כלומר, משתנה אחד, הוא פונקציה לינארית של השניים האחרים.
- לכן, נבחר שני משתנים בלבד מתוך השלושה ונבנה את המודל:

$$wage = \beta_0 + \beta_1 H + \beta_2 A + \varepsilon$$

משתנים קטגוריאליים - דוגמה

- במקרה זה נקבל ש:

- עבור בעלי השכלה יסודית:

$$wage = \beta_0 + \varepsilon$$

- עבור בעלי השכלה תיכונית:

$$wage = \beta_0 + \beta_1 + \varepsilon$$

- עבור בעלי השכלה אקדמית:

$$wage = \beta_0 + \beta_2 + \varepsilon$$

- כלומר, אפשרנו מודל שונה לכל קבוצת אוכלוסייה.

משתנים קטגוריאליים - דוגמה

- משמעות הבחירה במודל זה היא שהשכלה יסודית מהווה את קבוצת הבסיס וכל יתר הקבוצות נמדדות ביחס אליה.

- כך, β_1 הוא ההבדל בין השכלה תיכונית ליסודית.

- β_2 הוא ההבדל בין השכלה אקדמית להשכלה תיכונית.

- שימו לב כי $\beta_2 - \beta_1$ הוא ההבדל בין השכלה אקדמית לתיכונית.

הנחת אי תלות לינארית מלאה בין המשתנים המסבירים



- כזכור, משמעות המקדם של משתנה מסוים היא השינוי הצפוי ב- Y כאשר הוא עולה ביח' וכאשר כל שאר המשתנים המסבירים ללא שינוי.
- במידה ובנתונים קיימת תלות לינארית מלאה, כלומר ניתן לבטא משתנה אחד כקומבינציה לינארית של היתר, לא ניתן לאמוד את המקדם הנ"ל לאור העובדה שהתופעה פשוט לא קורית!

הנחת אי תלות לינארית מלאה בין המשתנים המסבירים



- נשים לב לנוסחה שהוצגה בשיעור הקודם:

$$\hat{\beta}_j = \frac{\sum_{i=1}^n e_{(j)i} (Y_i - \bar{Y})}{\sum_{i=1}^n e_{(j)i}^2} = \frac{\text{cov}(e_{(j)}, Y)}{\text{var}(e_{(j)})}$$

- כאשר $e_{(j)}$ הן השאריות מהרגרסיה של X_j על יתר המשתנים המסבירים.
- במידה והנחה 3 מופרת, המכנה פשוט שווה ל-0 והביטוי אינו מוגדר.

מולטי-קולינאריות



- לעיתים, למרות שהנחה 3 מתקיימת, קיים קשר לינארי חזק, אך לא מלא, בין המשתנים המסבירים.
- תופעה זו נקראת מולטי-קולינאריות והיא גוררת לעיתים בעיות חישוביות.
- בעיה נוספת שמתעוררת היא בטיב האמידה, קרי בשונות האומדים.

מולטי-קולינאריות

- כזכור, שונות האומדים היא:

$$\frac{\sigma^2}{n \text{var}(X)(1-R_{(j)}^2)}$$

- כאשר קיים קשר לינארי חזק בין המשתנים המסבירים, $R_{(j)}^2$ קרוב מאוד ל-1 ולכן השונות המתקבלת גבוהה מאוד מה שמקשה מאוד על הסקת מסקנות מהאמידה.
- פתרון אפשרי יהיה בד"כ הגדלת גודל המדגם.

מולטיקולינאריות

```
> nba$twoexper=nba$exper*2  
> model5nba <- lm(games ~ exper+twoexper, data = nba)  
> model5nba
```

```
Call:  
lm(formula = games ~ exper + twoexper, data = nba)
```

```
Coefficients:  
(Intercept)      exper      twoexper  
    61.5186      0.8217         NA
```

הנחת התוחלת המותנה

- הנחה מס' 4, $E(\varepsilon | X_1, \dots, X_k) = 0$ היא הנחה קריטית לתכונות חוסר ההטיה של אומדי OLS.

- במידה וההנחה מופרת, לא נוכל לומר שהאומדים חסרי הטיה ולכן גם לא נוכל להשתמש בסטטיסטיים T, F לצורך בדיקת השערות.

- בהמשך נתאר סיבות אפשריות להפרת הנחה וניתן דרך אפשרית להתמודדות עם הבעיה.

השמטת משתנה

- הפרת של הנחה 4 עלולה להיגרם עקב השמטת משתנה מהמודל כפי שיודגם להלן.
- נניח כי המודל האמתי, המקיים את הנחות הרגרסיה הוא:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$$

- אך מסיבה מסוימת אין לנו נתונים על X_2 ולכן אנחנו אומדים את המודל:

$$Y = \beta_0 + \beta_1 X_1 + u$$

- כאשר: $u = \beta_2 X_2 + \varepsilon$

השמטת משתנה

- המשמעות של "העברת" X_2 לטעות, היא חוסר היכולת "להחזיק" אותו קבוע כאשר X_1 משתנה.
- אם נניח כי X_1 ו- X_2 מקיימים את הקשר הבא:

$$X_2 = \alpha_0 + \alpha_1 X_1 + v$$

- נקבל שההשפעה ה**נצפית** של X_1 היא:

$$Y = \beta_0 + \beta_1 X_1 + \underbrace{\beta_2 X_2}_{u} + \varepsilon$$

השמטת משתנה

- המסקנה, השמטת עלולה לגרום להפרה של הנחה מס' 4 ולכן להטיית האומד.
- החדשות הטובות הן שבמקרים מסוימים נוכל להעריך את כיוון ההטיה.
- במקרה שתואר בשקופית הקודמת, ההטיה הייתה: $\alpha_1 \beta_2$
- בהתאם לסימן הפרמטרים נוכל להעריך האם ההטיה כלפי מעלה או כלפי מטה.
- שימו לב, השמטת משתנה לא תסב שום נזק במידה ואחד מהפרמטרים הנ"ל שווים ל-0.



דוגמא

$\beta_2 \text{games}$

$$\text{points} = \beta_0 + \beta_1 \text{exper} + \epsilon$$


- מה יש ב- ϵ ?
- למשל: מספר המשחקים שהשחקן שיחק
- האם שנעלה את exper ביחידה אחת (בממוצע) games יישאר אותו דבר?

דוגמא



דוגמא

- מה עושים?
 - מכניסים את games לתוך הרגרסיה!
- $$\text{points} = \beta_0 + \beta_1 \text{exper} + \beta_2 \text{games} + \epsilon$$






$$0.3301 = 0.151 * 0.822 + 0.206$$

- [illegible]

- $$\text{cov}(Z, X) \neq 0$$



משתני עזר - דוגמה

- במשוואת שכר כפונקציה של השכלה.
- השכלה עשויה להיות מתואמת עם "כשרון" המושמט מהרגרסיה.
- משתני עזר אפשריים הם:
 - השכלת ההורים.
 - מס' אחים.
 - (בארה"ב) רבעון שבו נולד הפרט.

TSLS

- אמידה בעזרת משתנה עזר נעשית בשני שלבים:
- בשלב הראשון אומדים את הרגרסיה:
$$X = \alpha_0 + \alpha_1 Z + u$$
- ומחשבים בעזרתה את התחזית של X באמצעות Z :
$$\hat{X} = \hat{\alpha}_0 + \hat{\alpha}_1 Z$$

TSLS

- בשלב השני אומדים את הרגרסיה:
$$Y = \beta_0 + \beta_1 \hat{X} + \varepsilon$$
- שימו לב שמובטח לנו ש:
$$\text{cov}(\hat{X}, \varepsilon) = 0$$
- כיוון ש- $\hat{X}$ הוא טרנספורמציה לינארית של Z .

TSLS

- אומדי TSLS אינם חסרי הטיה אך הם עקיבים, כלומר מתקיים:

$$\hat{\beta}_1^{IV} \xrightarrow{n \rightarrow \infty} \beta_1$$

- שונות האומד במקרה הפשוט תהיה: $\frac{\sigma^2}{n \text{var}(X) R_{X,Z}^2}$

- כלומר, ככל ש-X ו-Z מתואמים יותר כך שונות האומד תהיה קטנה יותר.

TSLS

- ניתן להשתמש בשיטה זו גם עבור מספר גדול יותר של משתני עזר.

- במידה והמודל כולל משתנים נוספים אקסוגניים, יש להשתמש גם בהם בשלב הראשון של TSLS.

THE EFFECTS OF EXPOSURE TO BETTER
NEIGHBORHOODS ON CHILDREN:
NEW EVIDENCE FROM THE MOVING
TO OPPORTUNITY EXPERIMENT


Raj Chetty
Nathaniel Hendren
Lawrence F. Katz

Moving to Opportunity (MTO) experiment



שתי השערות

- מעבר לאזור פחות עני משפר את התוצאות הכלכליות לטווח ארוך ארוך לילדים שהיו צעירים בזמן המעבר
- הרחוק ממעבר לאזור עוני נמוך יורדים עם גיל הילד במעבר



Moving to OPPORTUNITY for Fair Housing Demonstration Program



MTO experiment

- The MTO experiment was conducted between 1994 and 1998 in five large U.S. cities. The experimental sample included 4,604 families, who were randomly assigned to one of three groups: an experimental voucher group that was offered a subsidized housing voucher that came with a requirement to move to a census tract with a poverty rate below 10%, a Section 8 voucher group that was offered a standard subsidized housing voucher with no additional contingencies, and a control group that was not offered a voucher (but retained access to public housing).

Tax Data

- Income
- College Attendance
- College Quality
- Neighborhood Characteristics in Adulthood
- Marital Status and Fertility

Balance Tests and Summary Statistics

Prior research has documented that baseline characteristics are balanced between the treatment and control groups for both MTO adults and children, as would be expected in an experiment with random assignment (Kling et al. 2007). Here, we replicate these balance tests on the linked MTO-Tax Data to ensure that we retain balance in the subgroup that we are able to link to the tax data.

covariates appears to be balanced in the linked MTO-Tax data data. 13 of the 196 differences reported in Appendix Table 1a are significant with $p < 0.05$ and 2 of the 196 are significant with $p < 0.01$ based on t-tests that do not adjust for multiple comparisons, in line with what one would expect under random assignment.

Analysis and Results

1

$$y_i = \alpha + \beta_E^{ITT} Exp_i + \beta_S^{ITT} SS_i + \gamma X_i + s_i \delta + \epsilon_i$$

In our baseline specifications, we include randomization site dummies s (since randomization occurred within sites) but no additional covariates X , as the choice of which covariates to include is somewhat arbitrary. In supplemental specifications, we evaluate the sensitivity of our estimates to the inclusion of the 32 baseline covariates shown in Appendix Table 1a. Including these additional covariates affects the point estimates modestly and has little impact on the qualitative conclusions, as expected given that the covariates are balanced across the treatment groups.¹⁴

The estimates of β_E^{ITT} and β_S^{ITT} in (1) identify the causal impact of being offered a voucher to move through MTO. Since not all the families offered vouchers actually took them up, these ITT estimates understate the causal effect of actually moving to a different neighborhood. Following

2

$$y_i = \alpha_T + \beta_E^{TOT} TakeExp_i + \beta_S^{TOT} TakeS8_i + \gamma_T X_i + s_i \delta_T + \epsilon_i^T$$

where TakeExp and TakeS8 are indicators for taking up the experimental and Section 8 vouchers, respectively. Since TakeExp and TakeS8 are **endogenous variables**, we **instrument** for them using the randomly-assigned MTO treatment group indicators (Exp and S8) and estimate (2) using **two-stage least squares**. Under the assumption that MTO voucher offers only affect outcomes through the actual use of the voucher to lease a new residence, β_E^{TOT} and β_S^{TOT} can be interpreted as the causal effect of taking up the experimental and Section 8 vouchers and moving to a lower-poverty neighborhood (Angrist et al. 1996).¹⁵

3


$$y_i = \alpha_T + \beta_E^{TOT} TakeExp_i + \beta_S^{TOT} TakeS8_i + \gamma_T X_i + s_i \delta_T + \epsilon_i^T$$

where TakeExp and TakeS8 are indicators for taking up the experimental and Section 8 vouchers, respectively. Since TakeExp and TakeS8 are **endogenous variables**, we **instrument** for them using the randomly-assigned MTO treatment group indicators (Exp and S8) and estimate (2) using **two-stage least squares**. Under the assumption that MTO voucher offers only affect outcomes through the actual use of the voucher to lease a new residence, β_E^{TOT} and β_S^{TOT} can be interpreted as the causal effect of taking up the experimental and Section 8 vouchers and moving to a lower-poverty neighborhood (Angrist et al. 1996).¹⁵


$$TakeExp = \pi_0 + \pi_1 Exp + \pi_2 X + u_1 \quad TakeS8 = \gamma_0 + \gamma_1 S8 + \gamma_2 X + u_2$$

DOES COMPULSORY SCHOOL ATTENDANCE AFFECT SCHOOLING AND EARNINGS?

JOSHUA D. ANGRIST AND
ALAN B. KRUEGER




- לכל מדינה מפותחת בעולם יש דרישה לימוד חובה, אך מעט ידוע על ההשפעה שיש לחוקים אלה על הישגי השכלה והשתכרות.
- מאמר זה מנסה לנסות טבעי יוצא דופן כדי להעריך את ההשפעה של חוקי לימוד חובה בארצות הברית.



מיוון שסביר להניח שיום ההולדת של אדם לא נמצא בקורלציה עם תבנית אישיות מלבד גיל במנייה לבית הספר, שנת הלידה מייצגת שנות אסונות בחינת שנות להשקט בה כדי להעריך את ההשפעה של לימוד חובה על ההשכלה והרווחים

- נניח שאחוז התלמידים שרוצים לעזוב את בית הספר לפני שהם מגיעים לגיל הנשירה החוקי קבוע לאורך ימי ההולדת
- אז לחוק יש השפעה על תקופת הלימודים בפועל של תלמידים אלה
- תלמידים שנולדו בתחילת השנה הקלנדרית הם בדרך כלל מבוגרים יותר כשהם נכנסים לבית הספר מאשר ילדים שנולדו בסוף השנה
- מכאן שאם חלק קבוע מהתלמידים מוגבל על ידי חוק נוכחות חובה, ילידי תחילת השנה יקבלו פחות לימוד בממוצע מאלו שנולדו לקראת סוף השנה.

Years of Education and Season of Birth



- בחינה מדויקת של הגרפים מלמדת כי קיים דפוס קטן אך מתמשך במספר שנות השכלה הממוצעות לפי רבעון הלידה
- ההשכלה הממוצעת היא בדרך כלל גבוהה יותר עבור אנשים שמלודו לקראת סוף השנה מאשר עבור אנשים שמלודו בתחילת השנה

Outcome variable	cohort	Mean	t			[P-value]
Total years of education	1930-1939	12.79	-0.124	-0.086	-0.015	24.9
	1940-1949	13.56	-0.017	-0.017	-0.016	[0.0001]
High school graduate	1930-1939	0.77	-0.085	-0.035	-0.017	18.6
	1940-1949	0.86	-0.019	-0.019	-0.011	[0.0001]
Years of educ. for high school graduates	1930-1939	13.99	-0.019	-0.020	-0.004	46.4
	1940-1949	14.24	-0.002	-0.002	-0.001	[0.0001]
College graduate	1930-1939	0.30	-0.015	-0.012	-0.002	54.4
	1940-1949	0.30	-0.001	-0.001	-0.001	[0.0001]
Completed master's degree	1930-1939	0.09	-0.014	-0.014	-0.014	[0.0006]
	1940-1949	0.11	0.005	0.043	-0.003	7.8
Completed doctoral degree	1930-1939	0.03	-0.011	-0.011	-0.010	[0.0017]
	1940-1949	0.04	-0.002	-0.002	-0.002	[0.0021]
Completed master's degree	1930-1939	0.09	-0.002	-0.002	-0.002	[0.0018]
	1940-1949	0.11	-0.001	-0.001	-0.001	1.7
Completed doctoral degree	1930-1939	0.03	-0.001	-0.001	-0.001	[0.1399]
	1940-1949	0.04	0.000	0.004	0.001	3.9
Completed master's degree	1930-1939	0.03	-0.001	-0.001	-0.001	[0.0081]
	1940-1949	0.04	-0.002	-0.002	-0.002	2.9
Completed doctoral degree	1930-1939	0.03	-0.001	-0.001	-0.001	[0.0332]
	1940-1949	0.04	-0.002	-0.001	-0.001	4.3

THE EFFECT OF QUARTER OF BIRTH ON VARIOUS EDUCATION AL OUTCOME VARIABLES

- | Date of birth | Type of state law | | | Column 11 of 18 | |
|----------------------------------|-------------------|--------------|--------|-----------------|--|
| | Reaching age 18 | | | | |
| | Age 18 | Age 17 or 18 | Age 17 | | |
| Percent annualized April 1, 1980 | | | | | |
| 1. Jan 1-Mar 15, 1984 | 67.8 | 50.0 | -18.8 | (-1.4) | |
| 2. Apr 1-May 15, 1984 | 59.6 | 49.6 | 9.9 | (1.1) | |
| 3. Apr 1-Dec 31, 1984 | 59.2 | 49.6 | 9.5 | (1.1) | |
| 4. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 5. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 6. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 7. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 8. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 9. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 10. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 11. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 12. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 13. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 14. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 15. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 16. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 17. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 18. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 19. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 20. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 21. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 22. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 23. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 24. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 25. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 26. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 27. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 28. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 29. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 30. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 31. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 32. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 33. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 34. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 35. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 36. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 37. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 38. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 39. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 40. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 41. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 42. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 43. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 44. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 45. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 46. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 47. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 48. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 49. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 50. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 51. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 52. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 53. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 54. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 55. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 56. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 57. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 58. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 59. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 60. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 61. Jan 1-Mar 15, 1984 | 59.2 | 50.0 | -9.6 | (-0.8) | |
| 62. Jan 1-Mar 15, 1984</ | | | | | |

The graph plots Log Weekly Earnings on the vertical axis against the Year of Birth on the horizontal axis. The vertical axis has major tick marks at 5.64, 5.7, 5.8, and 5.9. The horizontal axis has major tick marks at 30, 35, 40, and 45. The data points are connected by a line, showing a fluctuating but generally downward-sloping trend. There is a significant dip in earnings around the year 1940, followed by a sharp decline after 1945.

-
-
-
-
-
-

	(1) Born in 1st quarter of year	(2) Born in 2nd, 3rd, or 4th quarter of year	(3) Difference (std. error) (1) - (2)
ln (wly. wage)	5.1484	5.1574	-0.00808 (0.00391)
Education	11.3996	11.5252	-0.1256 (0.0155)
Wald est. of return to education			0.0715 (0.0219)
OLS return to education*			0.0501 (0.0004)

	(1) Born in 1st quarter of year	(2) Born in 2nd, 3rd, or 4th quarter of year	(3) Difference (std. error) (1) - (2)
ln (wkly. wage)	5.8916	5.9027	-0.01110 (0.00274)
Education	12.6881	12.7969	-0.1088 (0.0192)
Wald est. of return to education			0.1020 (0.0239)
OLS return to education			0.0709

	(1) Born in 1st quarter of year	(2) Born in 2nd, 3rd, or 4th quarter of year	(3) Difference (std. error) (1) - (2)
ln (wkly. wage)	5.8916	5.9027	-0.01110 (0.00274)
Education	12.6881	12.7969	-0.1088 (0.0192)
Wald est. of return to education			0.1020 (0.0239)
OLS return to education			0.0709

ln (wkly. wage)	5.8916	5.9027	-0.0110 (0.00274)
Education	12.6881	12.7969	-0.1088 (0.0132)
Wald est. of return to education			0.1020 (0.0239)
OLS return to education			0.0709

$$(1) \quad E_i = X_i\pi + \sum_c Y_{ic}\delta_c + \sum_c \sum_j Y_{ic}Q_{ij}\theta_{jc} + \epsilon_i$$

$$(2) \quad \ln W_i = X_i\beta + \sum_c Y_{ic}\xi_c + \rho E_i + \mu_{1i}$$

where E_i is the education of the i th individual, X_i is a vector of covariates, Q_{ij} is a dummy variable indicating whether the individual was born in quarter j ($j = 1, 2, 3$), and Y_{ic} is a dummy variable indicating whether the individual was born in year c ($c = 1, \dots, 10$), and W_i is the weekly wage. The coefficient ρ is the return

- To improve efficiency of the estimates and control for age-related trends in earnings, we estimated the following TSLS model
